

회귀분석 기초

다중회귀분석

김현우, PhD¹

¹충북대학교 사회학과 조교수

July 7, 2025



진행 순서

- 1 다중회귀분석 입문
- 2 표준화 회귀계수
- 3 모형의 적합도
- 4 회귀분석의 결과표

다중회귀분석 입문

다중회귀분석 입문

현실에서는 아무도 단순회귀모형을 사용하지 않는다.

- 단순회귀모형(simple regression model)에서는 오로지 독립변수 X 와 종속변수 Y , 딱 두 개의 변수만 고려하였다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 하지만 이것은 학습용 혹은 연습용에 불과하다.
- (종속변수는 여전히 1개지만) 모형 안에 k 개의 독립변수가 투입된 경우를 다중회귀모형(multiple regression model)이라고 부른다.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \epsilon_i$$



다중회귀분석은 특정 변수의 순효과를 살펴보는데 유용하다.

- 가령 제조업종사자비율이 순이동률에 영향을 미친다는 회귀모형을 세우고, 오차항을 최소화하는 b_0 와 b_1 을 다음과 같이 추정하였다고 하자.

$$\text{순이동률} = -4.884 + 0.137 \cdot \text{제조업종사자비율}$$

- “제조업 종사자 비율이 1 퍼센트 증가할 때, 해당 지역의 순이동률은 0.137 만큼 증가한다.”
- “제조업 종사자 비율이 0 퍼센트인 지역의 평균 순이동률은 -4.88이다.”
- 하지만 순이동률과 관련있는 변수는 제조업 종사자 비율 이외에도 많다!



다중회귀모형 입문

- k 개의 독립변수를 모형에 투입했다면 회귀계수는 각각 대응하는 변수의 변동이 종속변수에 미치는 영향을 반영한다(Why?).
- 그러므로 다중회귀분석은 다른 변수들의 효과를 통제한 상태에서 특정 변수의 **순효과** (net effect) 또는 **부분효과**(partial effect)를 살펴보는데 유리하다.
- 가령 제조업종사자비율) 외에, 고차서비스비율) 역시 (순이동률)에 영향을 미칠 것이다.

$$\text{순이동률} = b_0 + b_1 \cdot \text{제조업종사자비율} + b_2 \cdot \text{고차서비스비율} + e$$

- 다중회귀분석을 통해 ‘고차 서비스업 비율의 효과를 통제했을 때 (또는 고차 서비스업 비율이 똑같은 때)’ 제조업 종사자 비율이 한 단위 변화하면, 순이동률이 얼마만큼 변화하는지 살펴볼 수 있다.



연습 4. 고래는 mobility.csv를 사용하여 순이동률을 설명하는 회귀분석을 다시 한 번 수행하고자 한다. 이번에는 독립변수로 제조업종사자비율, 고차서비스비율, 지가변동율, 신규주택비율, 평균교육연수, 천명당공원면적, 만명당문화시설수를 함께 투입하기로 하였다.



다중회귀분석 입문

모함 요약

모형	R	R 제곱	수정된 R 제곱	추정값의 표준 오차
1	.703 ^a	.495	.478	4.3970008299

a. 예측자: (상수), 만명당문화시설수, 지가변동율, 천명당공원면적, 고차서비스비율, 신규주택비율, 제조업종사자비율, 평균교육연수

ANOVA^a

모형	제곱합	자유도	평균제곱	F	유의확률
1 회귀	4161.683	7	594.526	30.751	<.001 ^b
잔차	4253.396	220	19.334		
전체	8415.079	227			

a. 종속변수: 수이동물

b. 예측자: (상수), 만명당문화시설수, 지가변동률, 천명당공원면적, 고차서비스비율, 신규주택비율, 제조업종사자비율, 평균교육연수

계수^a

모형		비표준화 계수		표준화 계수	t	유의확률
		B	표준화 오류	베타		
1	(상수)	-17.718	2.703		-6.555	<.001
	제조업종사자비율	.067	.023	.176	2.903	.004
	고차서비스비율	-.089	.077	-.085	-1.148	.252
	지가변동율	.050	.099	.027	.507	.613
	신규주택비율	.349	.040	.506	8.627	<.001
	평균교육연수	.867	.327	.212	2.649	.009
	전명당공원면적	-.018	.008	-.111	-2.255	.025
	만명당문화시설수	.026	.086	.017	.298	.766

a. 종속변수: 수이동률

다중회귀분석 입문

다중회귀분석을 수행할 때는 변수의 사전 체크에 주의를 기울여야 한다.

- 여러 개의 독립변수를 모형에 한꺼번에 투입하다보면 하나하나를 꼼꼼하게 살펴보지 않고 그냥 대충 집어넣는 경우가 많다. 이것은 매우 위험하다!
- 개별 변수의 척도(scale)가 어떻게 구성되어 있는지, 분포(distribution)는 어떠한지, 극단치(outlier)는 없는지, 결측치(missing values)가 있는지 등을 반드시 살펴보아야 한다.
- SPSS에서도 정렬(sorting) 등을 통해 꼼꼼히 자료를 살펴보아야 하고, [그래프]-[차트 작성기]에서 '히스토그램' 등을 체크해야 한다.
- 단순회귀분석에 비해 표본 크기(sample size)가 얼마나 달라지는지도 확인해야 한다 (Why?).



다중회귀분석 입문

다중회귀분석에서는 보통 변수들의 역할을 구분한다.

- 관심변수(variables of interest)와 통제변수(control variables)를 구분하는 것이 대표적이다.
- 사회과학 연구에서 응용통계의 쓰임새는 결국 근거(증거)를 마련하는 것일 뿐, 우리는 나름의 핵심 주장을 가지고 있기 마련이다.
- 그 핵심 주장을 검증하기 위해 꼭 필요한 변수들이 관심변수 역할을 수행하고, 나머지는 단지 통제변수에 지나지 않는다.
- 연구 가설에 따라 “제조업 종사자 비율이 인구 순이동률에 미치는 영향”에 관심이 있다면 제조업 종사자 비율이 관심변수가 되고, 나머지 (잠재적으로 인구 순이동률에 영향을 미칠지도 모르는) 다른 모든 독립변수들은 통제변수 정도로 취급된다.
- 하지만 이것은 어디까지나 주관적으로 부여하는 의미일 뿐이고, 회귀모형 안에서 변수들의 지위는 평등하다(Why?).



다중회귀분석 입문

- 단순회귀분석 결과와 비교하여, 다중회귀분석에서 얻은 제조업종사자비율의 회귀계수가 어떻게 달라졌는지 꼭 비교해보자.
- 단순회귀분석에서 $b_1 = 0.1366$ 였고, 다중회귀분석에서 $b_1 = 0.067$ 로 크게 감소하였다.
- 이 차이가 무엇을 의미하는지 직관적으로 탐구해보자. 다중회귀분석에서 b_1 은 다른 통제변수들로 설명되고 남은 순이동률을 제조업종사자비율이 얼마나 설명하는지를 보여준다(Why?).
- 다중회귀분석 속에 투입한 독립변수의 구성에 따라 당연히 b_1 이 달라진다(Why?).



표준화 회귀계수

표준화 회귀계수

여러 독립변수 중 어떤 변수가 가장 강력한 영향요인인지 궁금할 수 있다.

- 회귀계수 절대값의 크기로 변수 간 영향력의 차이를 비교할 수 없다(Why?).
- 이를 비교하기 위한 한가지 방법은 **표준화 회귀계수(standardized regression coefficient)**를 사용하는 것이다.
- 표준화에도 몇 가지 방법이 있는데 대체로 다음을 사용한다.

$$\beta_k^* = \frac{s_{X_k}}{s_Y} b_k$$

- 여러 변수들의 표준화 회귀계수를 비교하여 어떤 변수가 얼마나 중요한지 알 수 있다.



연습 5. 고래가 앞서 수행한 다중회귀분석의 결과에 따르면, 인구 순이동률의 가장 강력한 독립변수는 무엇인가?



표준화 회귀계수

- 순서대로 신규주택비율, 평균교육연수, 제조업종사자비율, 천명당공원면적이 중요함을 알 수 있다.
- 이때 표준화 회귀계수를 직접 해석하는 방법은 아래와 같다(Why?).
- “신규주택비율이 1 표준편차 만큼 증가할 때, 순이동률은 0.349 표준편차만큼 증가한다.”
- 경험법칙(empirical rule)에 따르면, (독립변수와 종속변수가 모두 정규분포한다는 가정 아래) 1 표준편차 증가가 상당히 큰 변화임을 시사한다. 평균에서 1, 2, 3 표준편차는 각각 전체의 68%, 95%, 99.7%를 포함하기 때문이다.
- 특히 합성변수(composite variable)를 사용할 때, 표준화 회귀계수를 통한 해석이 중요해진다(Why?).



모형의 적합도

모형의 적합도

개발한 회귀모형이 현실 자료에 얼마나 적합한지 살펴보아야 한다.

- 우리가 모형을 세워 그것을 현실 자료에 맞추어(fit) 본 이상, 이것이 얼마나 잘 맞는가를 말할 수 있어야 한다. 이것이 모형의 **적합도(goodness-of-fit)**이다.
- 우리는 여러가지 적합도 지표 가운데 **결정계수(coefficient of determination)**와 **일원분산분석(one-way ANOVA)**만 살펴보기로 한다.



모형의 적합도

첫번째로 결정계수를 간단히 살펴보자.

- 주어진 자료에 **전체 변량(total variation)**이 있다면, 이것은 (모형에 의해) **설명된 변량(explained variation)**과 (그렇지 못하고) **남은 변량(residual variation)**의 합이라고 분해될 수 있다.

$$\sigma_{total}^2 = \sigma_{explained}^2 + \sigma_{residual}^2$$

- 그렇다면 설명된 변량 $\sigma_{explained}^2$ 와 전체 변량 σ_{total}^2 의 비율은 모형의 높은 설명력을 의미한다고 볼 수 있다.

$$R^2 = \frac{\sigma_{explained}^2}{\sigma_{total}^2} = 1 - \frac{\sigma_{residual}^2}{\sigma_{total}^2}$$

- 그러므로 결정계수 R^2 는 설명된 변량과 전체 변량의 비율이므로 0과 1 사이에 놓인다. 1에 가까울수록 모형은 높은 적합도를 보인다고 할 수 있다.
- 만약 R^2 가 0.45라면 “이 회귀모형은 주어진 자료의 전체 변량의 45% 를 설명한다”고 해석할 수 있다.

모형의 적합도

두번째로 일원분산분석을 간단히 살펴보자.

- 아래와 같이 선형회귀모형을 설정하였을 때 최악의 추정 결과는 무엇일까?

$$Y = \beta_0 + \beta_1 X + \cdots + \beta_{k-1} X_{k-1} + \beta_k X_k + \epsilon$$

- 그것은 모든 회귀계수가 0이 되는 상황이다(Why?)!

$$\beta_1 = \beta_2 = \cdots = \beta_{k-1} = \beta_k$$

- 제대로 된 모형이라면 최소한 이런 경우는 부정할 수 있어야 한다. 이 귀무가설조차 부정할 수 없다면, “이 모형은 완전히 쓸모없다”는 말이나 마찬가지다.



모형의 적합도

- 그러므로 다음과 같은 가설구조를 검증해 볼 수 있다.

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_{k-1} = 0 = \beta_k = 0$$

$$H_a : (\beta_1 \neq 0) \text{ or } (\beta_2 \neq 0) \text{ or } \cdots \text{ or } (\beta_{k-1} \neq 0) \text{ or } (\beta_k \neq 0)$$

- 이 가설구조를 테스트할 수 있는 방법은 일원분산분석(one-way ANOVA)이다.
- 다중회귀분석의 맥락에서 F 값은 다음과 같다. 단 k 는 독립변수의 수를 뜻한다.

$$F_{(k, n-k-1)} = \frac{\sigma_{explained}^2}{\sigma_{residual}^2} = \frac{MS_{explained}}{MS_{residual}} = \frac{SS_{explained}/k}{SS_{residual}/(n-k-1)}$$

- F 값이 충분히 크면 유의확률(p -value)이 작아지므로 위 귀무가설을 기각할 수 있다.



모형의 적합도

연습 6. college.sav를 사용하여 졸업생 평균수입(earnings)을 종속변수로, 학자금 상환비율(debt)과 등록금(cost)을 독립변수로 한 다중회귀분석을 수행한 뒤, 그 모형적합도를 해석하시오.



모형의 적합도

- “학자금 상환비율과 등록금 두 독립변수를 사용한 선형모형은 자료의 전체 변량 중 36.2%를 설명한다.”
- 0.362라는 결정계수는 너무 낮을까? 그렇지만도 않다. 겨우 두 개의 변수만으로 이 정도 설명했다는 것은 나름 훌륭하다(분과에 따라 해석이 상이하다).
- 결정계수는 보다 많은 독립변수를 집어넣을 때 지속적으로 팽창하는 성향이 있다. 그런데 이것은 **오컴의 면도날 원칙(Occam's Razor)**에 반하는 것이므로, 독립변수를 추가적으로 집어넣을 때마다 적절한 패널티를 가할 필요가 있다.
- **조정된 결정계수(adjusted R^2)**가 바로 이렇게 패널티가 가해진 결정계수이다 (여기서는 별 차이가 없었다).



모형의 적합도

- ANOVA 표의 유의확률이 0.001보다 작다는 사실은 99.9% 신뢰수준에서 다음의 귀무가설을 기각할 수 있다는 의미이다(Why?).

$$H_0 : \beta_1 = \beta_2 = 0$$

- 우리는 “모든 회귀계수가 0이다”라는 귀무가설을 기각하고 “최소한 하나의 회귀계수는 0이 아니다”라는 대립가설을 채택할 수 있었다. 다행이다~

ANOVA^a

모형		제곱합	자유도	평균제곱	F	유의확률
1	회귀	2244294783.2	2	1122147391.6	32.065	<.001 ^b
	잔차	3954566940.9	113	34996167.619		
	전체	6198861724.1	115			

a. 종속변수: Earnings

b. 예측자: (상수), Debt, Cost



회귀분석의 결과표

회귀분석의 결과표

회귀분석의 결과표를 엑셀로 복사해 붙여넣고 가지런하게 꾸며야 한다.

- 회귀분석 결과표에는 SPSS에서 사용하던 변수명을 그대로 남겨두지 말고 (독자가 알아볼 수 있도록) 똑바로 고쳐써야 한다.
- 결과표 안에 회귀계수 뿐 아니라, 표준오차(standard error), t 값, 또는 신뢰구간(confidence interval) 셋 중 하나는 함께 보고해야 한다(Why?).
- 통계적으로 유의하지 않았다고 포함했던 변수를 멋대로 표에서 빼서는 안된다(물론 상수도 마찬가지이다).
- 표가 너무 길어지면 (연구에서 핵심이 아닌) 변수들은 생략하는 관행도 있다. 그러나 이 경우에도 어떤 변수를 생략했는지 논문에서 반드시 보고해야 한다.



회귀분석의 결과표

유의확률에 관한 정보를 요약하기 위해 *을 붙인다.

- 유의확률이 0.001보다 작으면 상관계수 옆에 별 3개(***), 0.01보다 작으면 별 2개(**), 0.05보다 작으면 별 1개(*), 0.1보다 작으면 대거(dagger) 하나(†)를 붙일 수 있다.
- 물론 이런 표식은 통계적으로 유의하게 귀무가설을 기각할 수 있음을 의미한다.
- 유의확률에 따른 별 붙이기는 관습의 문제이고 연구자마다 다르다(어떤 이들은 아예 붙이지 않는다).



회귀분석의 결과표

〈표 4〉 고3 학업성취도에 대한 회귀분석의 결과 1

	모형 1		모형 2		모형 3	
	계수	표준오차	계수	표준오차	계수	표준오차
비밀번호 ¹	.062**	.179	.017	.155	.019	.154
중3 학업성취도			.509***	.008		
남성 ²					-.009	.107
자아존중감					.165***	.014
학습시간					.091***	.008
학습태도					.355***	.013
교사-학생 관계					.046*	.019
가구소득					.056**	.114
부모 관리/전문직 ³					.034	.116
부모 태졸 이상 ⁴					.055**	.123
부모 감독					-.005	.035
부모 애정					.009	.029
4년제 대학교 졸업 부모 세대 ⁵					.082**	.194
대학원 졸업 부모 세대 ⁶					.099***	.253
아직 정해지지 않은 부모 세대 ⁵					.028	.243
상수	8.952***	.065	6.498***	.126	-.819	.985
사례수	1,361		1,361		1,361	
결정계수	.004		.261		.285	

^{***} $p < .01$, ^{**} $p < .05$, ^{*} $p < .1$.

계수는 표준화 회귀계수, 단, 상수의 계수는 비표준화 회귀계수.

기준집단: 1 = 일반고; 2 = 여성; 3 = 부모 비전문/관리직; 4 = 부모 고졸 이하; 5 = 2-3년제 전문대학 졸업 이하 부모 기대.

회귀분석의 결과표

연습 7. MCAS.SAV에서 (메사추세츠 주의 224개 학군별로 수집된) 학생 대 교사 비율(str), 교사의 평균 연봉(tsal), 가계소득 중앙값(inc), 한부모가계 비율(sgl)이 학업성취도 평균점수(score)와 어떤 연관성을 맺고 있는지 회귀분석을 수행하고 회귀계수 및 유의성 검정 결과를 해석하시오.



회귀분석의 결과표

- 세부적인 것은 (각자의 분야에서) 출판된 논문을 최대한 훑내다가면서 배운다.
- “교사의 평균 연봉(tsal), 가계소득 중앙값(inc), 한부모가계 비율(sgl)의 효과를 통제하였을 때, 학생 대 교사 비율(str)이 10% 증가할 때마다 학업성취도 평균점수는 4.96점 씩 감소한다.”

	A	B	C	D	E	F	G	H	I	J	K
1											
2		회귀계수	표준오차		계수 ^a						
3	학생 대 교사 비율(%)	-0.496***	(0.131)		모형		비표준화 계수	표준화 계수	t		유의확률
4	교사의 평균 연봉(1,000달러)	-0.023	(0.075)				회귀계수	표준오차	베타		
5	가계소득 중앙값(1,000달러)	0.293***	(0.034)		1	(상수)	231.894	3.370		68.819	0.000
6	한부모가계 비율(%)	-0.878***	(0.174)			학생 대 교사	-0.496	0.131	-0.168	-3.794	0.000
7	상수	231.9***	(3.370)			교사의 평균 연봉	-0.023	0.075	-0.016	-0.314	0.754
8						가계소득 중앙	0.293	0.034	0.533	8.511	0.000
9	표본크기		224			한부모가계 비	-0.878	0.174	-0.278	-5.055	0.000
10	결정계수		0.617		a. 종속변수: 학업성취도 평균점수(MCAS)						
11	수정된 결정계수		0.61								
12	참고: 종속변수는 학업성취도 평균점수(MCAS)임. 괄호 안은 표준오차. *p < 0.05, **p < 0.01, ***p < 0.001.										

