

회귀분석 기초

선형회귀모형 시작하기

김현우, PhD¹

¹충북대학교 사회학과 조교수

July 7, 2025



진행 순서

- 1 자료의 직선 요약
- 2 회귀계수와 상수의 도출
- 3 회귀계수와 상수의 유의성 검정

자료의 직선 요약

자료의 직선 요약

독립변수 X 와 종속변수 Y 사이의 관계를 선으로 나타내보자.

- 선형회귀모형(linear regression model)을 이해하기 위해 먼저 일차방정식(linear equation)을 상상해보자.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 하첨자 i 가 붙어있으므로 관찰값(observation)에 따라 상이한 X_i 와 Y_i , ϵ_i 를 담게 된다.
- 이때 β_0 를 상수(constant) 또는 절편(intercept)이라고 부르고, β_1 를 회귀계수(regression coefficient) 또는 기울기(slope)라고 부른다.
- 한편 β_0 와 β_1 를 어떻게 설정하더라도 결국 자료를 완벽하게 설명할 수는 없다(Why?). 따라서 오차항(error term) ϵ_i 을 선형회귀모형에 추가한다.



자료의 직선 요약

- 여러분이 이미 상관분석(correlation analysis)을 배웠다면 적합선(fitting line) 개념이 익숙할 것이다.
- 주어진 자료의 두 양적 변수(quantitative variable) X 와 Y 사이에 가장 잘 맞는 직선(best-fitting straight line)을 그어 그 관계를 나타내 보일 수 있다.
- 이렇게 자료를 관통하는 하나의 선을 찾아내는 절차가 바로 회귀분석(regression analysis)의 핵심이다!




자료의 직선 요약

연습 1. lungcancer.sav는 8개 북유럽 국가의 1인당 담배 소비량(smoke)과 인구 100만 명당 폐암 발병자수(cancer)를 나타내고 있다. 독립변수와 종속변수를 선택한 뒤, 둘 사이의 관계를 나타내기 위해 가장 잘 맞는 직선을 그리시오. 회귀식을 도출하고 관계를 해석하시오.



자료의 직선 요약

- 1인당 담배 소비량(smoke)이 100만 명당 폐암 발병자수(cancer)에 영향을 미친다고 보는 것이 타당하다.
- SPSS에서 [그래프]-[차트 작성기]에서 적합선이 있는 산점도(scatterplot)를 선택한다.
- 어떤 조건을 갖춘 적합선이 가장 잘 데이터를 나타낼 수 있을까? 만일 기울기와 절편이 달라지면 어떤 결과가 될까?



자료의 직선 요약

- SPSS에서 [분석]-[회귀분석]-[선형]을 선택하여 추정된 회귀식은 다음과 같다.

$$\hat{Y} = 21.511 + 0.355X$$

- 즉, $\hat{\beta}_0 = 21.511$ 이고 $\hat{\beta}_1 = 0.355$ 이다. 추정량(estimated)에는 이렇게 $\hat{}$ (hat)을 붙인다.
- “국가의 1인당 담배 소비량이 한 단위 증가할 때, 100만 명당 폐암 발병자수는 0.355명 만큼 증가한다.”
- “아무도 흡연하지 않은 국가에서 100만 명당 폐암 발병자수는 21.511명이다.”
- 독립변수 X 의 값이 한 단위 변화하면 회귀계수 β_1 만큼 종속변수 Y 에 영향을 미친다.
- 회귀계수 및 상수의 해석은 무척 단순하지만 연습을 필요로 한다!



회귀계수와 상수의 도출

회귀계수와 상수의 도출

오차를 전반적으로 최소화하는 적합선이야말로 가장 잘 맞는 직선이다.

- SPSS에서 그려진 적합선과 회귀식은 도대체 어떻게 추정된 것일까?
- 일단 회귀식이 추정되었다면 새로운 X_i 값이 주어질 때, (그에 대응하는) Y_i 를 예측(predict)할 수 있다.
- 실제 자료 Y_i 와 예측된 $\hat{Y}$ 간의 차이는 곧 오차(error)라고 볼 수 있다(Why?).

$$\begin{aligned}\epsilon_i &= Y_i - \hat{Y}_i \\ &= Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X_i)\end{aligned}$$



회귀계수와 상수의 도출

- 예상되는 오차 ϵ_i 를 줄이는 것은 현실 자료와 이론적 예측 사이의 괴리를 줄이는 것과 일맥상통한다(Why?).
- 물론 오차 하나만 줄이는 것이 아니라 오차를 전체적으로 줄이는 것이 중요하다.
- 이때 (오차의 합을 그냥 최소화하지 않고) **오차 제곱의 합(sum of squared error; SSE)**을 최소화한다(Why?).
- 오차 제곱의 합을 최소화하는 β_0 와 β_1 을 찾음으로써, 주어진 자료를 가장 잘 설명할 수 있는 모형을 만들 수 있게 된다.

$$\operatorname{argmin}_{\beta_0, \beta_1} \sum_{i=1}^n \epsilon_i^2$$

- 이것이 바로 **보통최소제곱(ordinary least squares; OLS)**이다.



회귀계수와 상수의 도출

회귀식을 일단 추정했다면 이제 마음껏 예측에 사용할 수 있다!

- 추정된 상수 $\hat{\beta}_0$ 와 회귀계수 $\hat{\beta}_1$ 를 통해 예측된(predicted) Y , 즉 $\hat{Y}$ 을 얻을 수 있다.
- 추정된 회귀식은 다음과 같으므로, 독립변수인 smoke에 원하는 값을 대입하면 종속변수인 cancer를 예측할 수 있다.

$$\widehat{\text{cancer}} = 21.511 + 0.355 \cdot \text{smoke}$$

- 만일 1인당 담배 소비량이 1000인 가상의 국가에서는 인구 100만 명당 폐암 발병자수가 몇 명인지 예측해보자.
- 1인당 담배 소비량이 평균이라면 인구 100만 명당 폐암 발병자수는 몇 명일까?
- 예측은 회귀분석의 대단히 유용한 기능 중 하나이다. 이것으로 주가(stock price)나 집값 등에 관한 모형을 세우고 회귀계수 및 상수를 추정한 뒤, 조건별로 가격을 예측해 볼 수 있다.



회귀계수와 상수의 도출

연습 2. 중고차 딜러 새우는 자사에서 취급하고 있는 K모델 승용차 10대의 연식과 가격을 조사하였다(usedauto.sav). 연식(age)이 가격(price)에 어떠한 영향을 미치는지 (1) 산점도를 그리고 (2) 회귀식을 추정하시오. 만일 연식이 8년 된 차량이 입고되었다면 얼마에 내놓는 것이 합리적인지 예측하시오.



회귀계수와 상수의 도출

입력/제거된 변수^a

모형	입력된 변수	제거된 변수	방법
1	age ^b	.	입력

a. 종속변수: price

b. 요청된 모든 변수가 입력되었습니다.

모형 요약

모형	R	R 제곱	수정된 R 제곱	추정값의 표준 오차
1	.847 ^a	.717	.682	5.371

a. 예측자: (상수), age

ANOVA^a

모형		제곱합	자유도	평균제곱	F	유의확률
1	회귀	585.225	1	585.225	20.287	.002 ^b
	잔차	230.775	8	28.847		
	전계	816.000	9			

a. 종속변수: price

b. 예측자: (상수), age

계수^a

모형		비표준화 계수 B	표준화 오차 표준화 오차	표준화 계수 비타	t	유의확률
1	(상수)	41.125	4.573		8.993	.000
	age	-3.825	.849	-.847	-4.504	.002

a. 종속변수: price

- 특히 초보일 때는 회귀식을 직접 써보면서 해석을 시도하자.

$$\text{price} = 41.125 - 3.825 \cdot \text{age}$$

- “연식이 1년 증가할수록 중고차 가격은 3,825달러씩 떨어진다.”
- “연식이 0년인 중고차 가격은 41,125달러가 된다.”



회귀계수와 상수의 유의성 검정

회귀계수와 상수의 유의성 검정

회귀분석에서도 표본을 넘어 모집단의 성격을 추론할 필요가 있다.

- 설령 우리가 자료에서 회귀계수와 상수를 구했다고 하더라도, 이것은 어디까지나 표본 자료이므로 **통계량(statistic)**일 뿐이다.
- 그렇기 때문에 **모집단에서의 회귀모형**과 **표본에서의 회귀모형**은 개념적으로 구별될 수 있다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i \quad (\text{모집단 회귀모형})$$

$$Y_i = b_0 + b_1 X_i + e_i \quad (\text{표본 회귀모형})$$

- ϵ_i 가 **오차항(error term)**이라고 불리우는 반면, e_i 는 **잔차항(residual term)**이라고 불리운다(하지만 종종 잔차도 그냥 오차라고 부른다).



회귀계수와 상수의 유의성 검정

- 가설을 세우는 대상은 ‘모집단’의 상수와 회귀계수, 즉 **모수(parameter)**임에 주의하자.
- 상수에 대해서는 다음의 가설을 세운다.

$$H_0 : \beta_0 = 0$$

$$H_a : \beta_0 \neq 0$$

- 회귀계수에 대해서는 다음의 가설을 세운다.

$$H_0 : \beta_1 = 0$$

$$H_a : \beta_1 \neq 0$$



회귀계수와 상수의 유의성 검정

- 모집단에서 수많은 표본을 뽑아 그로부터 상수 b_0 와 회귀계수 b_1 를 추정한 뒤, 이것들의 표집분포(sampling distribution)를 구축해 볼 수 있다.
- (1) 표본 회귀모형 $Y = b_0 + b_1X + e$ 에 대해 정규성(normality)을 가정하거나,
(2) 중심극한정리(central limit theorem)에 힘입어, 다음을 알 수 있다.

$$\beta_0 = E(\hat{b}_0)$$

$$\beta_1 = E(\hat{b}_1)$$

- (상수항과 회귀계수의) ‘표집분포의 표준편차’를 표준오차(standard error)라고 부른다.



회귀계수와 상수의 유의성 검정

t 분포를 사용하여 회귀계수와 상수에 대한 유의성 검정을 수행한다.

- 귀무가설(null hypothesis)이 옳다는 전제 아래, t 분포하는 표집분포를 우선 그려보자.
- 주어진 표본에서 회귀분석으로 추정된 회귀계수 $\hat{b}_1$ 의 t 값은 아래와 같다.

$$t = \frac{\hat{b}_1 - \beta_1}{se_{\hat{b}_1}} = \frac{\hat{b}_1}{se_{\hat{b}_1}}$$

- 이때 t 분포의 자유도(degree of freedom)는 $n - 2$ 이다.



회귀계수와 상수의 유의성 검정

- 앞서 구한 t 값의 위치를 표집분포 위에서 살펴보고, 그보다 극단적인 t 값을 얻게 될 확률인 **유의확률(p -value)**을 계산한다.
- 이때 **양측검정(two-tailed test)**인지 **단측검정(one-tailed test)**인지 주의한다.
- 만일 유의확률이 0.05보다 작다면, 5% 유의수준 또는 95% 신뢰수준에서 귀무가설 ($H_0 : \beta_1 = 0$)을 기각하고 대립가설 ($H_a : \beta_1 \neq 0$)을 채택할 수 있다.



회귀계수와 상수의 유의성 검정

연습 3. 고래는 요즘 지방소멸 걱정에 잠을 이루지 못하고 있다. 어차피 잠도 안오는데 논문이나 쓰자고 마음먹은 고래는 일어나 컴퓨터 앞에 앉았다. 고래는 우리나라 시군구 수준 자료를 이미 확보하였고 (mobility.csv와 mobility.pdf), 순이동률이 0보다 작다면 인구 순유출을 뜻한다는 것에 착안하여, 제조업 활성화 수준이 지역인구 변동에 어떠한 영향을 미치는지 살펴보고자 한다.

- (1) 독립변수를 제조업종사자비율로 종속변수를 순이동률로 하여 회귀분석을 수행하시오.
- (2) 추정된 회귀식을 제시하고 유의성 검정을 수행한 뒤, 이를 해석하시오.
- (3) 제조업종사자비율이 18%인 지역은 인구가 순유입될지 아니면 순유출될지 예측하시오.



회귀계수와 상수의 유의성 검정

- 제조업종사자비율이 순이동률에 영향을 미친다는 회귀모형을 세우고, 오차제곱합을 최소화하는 b_0 와 b_1 을 다음과 같이 추정할 수 있다.

$$\text{순이동률} = -4.88 + 0.137 \cdot \text{제조업종사자비율}$$

- “제조업 종사자 비율이 1 퍼센트 증가할 때, 해당 지역의 순이동률은 0.137만 큼 증가한다.”
- “아무도 제조업에 종사하지 않는 지역의 평균 순이동률은 -4.88이다.”



회귀계수와 상수의 유의성 검정

- 회귀계수 부분을 살펴보면 $b_1 = 0.137$ 이고 $se_{\hat{b}_1} = 0.024$ 이다. 그러므로 t 값은 5.80 ($=0.137/0.024$)이다.
- 양측검정에서 이러한 t 값보다 극단적인 값이 나올 확률은 0.001보다 작다.
- 그러므로 $\beta_1 = 0$ 이라는 귀무가설을 0.1% 유의수준에서 자신있게 기각할 수 있다.
- “제조업 종사자 비율은 99.9% 신뢰수준에서 (또는 0.1% 유의수준에서) **통계적으로 유의하게(statistically significantly)** 순이동률과 연관되어 있다.”
- 보통 통계적으로 유의하지 않으면 (찾잔 속의 태풍이므로) 해석을 아예 하지 않는 경우가 많다.



회귀계수와 상수의 유의성 검정

- 마지막으로 추정된 상수 $\hat{b}_0$ 와 회귀계수 $\hat{b}_1$ 을 가지고 $\hat{Y}$ 을 구할 수 있다.
- 앞서 추정된 결과에 따르면 $\hat{b}_0 = -4.884$ 이고 $\hat{b}_1 = 0.137$ 이므로, 독립변수인 제조업 종사자비율에 특정 값(18)을 대입하면, 종속변수 예측값 $\widehat{\text{순이동률}}$ 을 얻을 수 있다.

$$\widehat{\text{순이동률}} = -4.884 + 0.137 \cdot 18 = -2.42$$

- “제조업 종사자 비율이 18%인 지역의 예상 순이동률은 -2.42이다. 즉 인구 순유출이 예상된다.”

