

# 회귀분석 기초

## 다중회귀분석

김현우, PhD<sup>1</sup>

<sup>1</sup>충북대학교 사회학과 조교수

July 7, 2025



# 진행 순서

- 1 다중회귀분석 입문
- 2 표준화 회귀계수
- 3 모형의 적합도
- 4 회귀분석의 결과표

# 다중회귀분석 입문

# 다중회귀분석 입문

현실에서는 아무도 단순회귀모형을 사용하지 않는다.

- **단순회귀모형(simple regression model)**에서는 오로지 독립변수  $X$ 와 종속변수  $Y$ , 딱 두 개의 변수만 고려하였다.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- 하지만 이것은 학습용 혹은 연습용에 불과하다.
- (종속변수는 여전히 1개지만) 모형 안에  $k$ 개의 독립변수가 투입된 경우를 **다중회귀모형(multiple regression model)**이라고 부른다.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \epsilon_i$$



다중회귀분석은 특정 변수의 순효과를 살펴보는데 유용하다.

- 가령 제조업종사자비율이 순이동률에 영향을 미친다는 회귀모형을 세우고, 오차항을 최소화하는  $b_0$ 와  $b_1$ 을 다음과 같이 추정하였다고 하자.

$$\text{순이동률} = -4.884 + 0.137 \cdot \text{제조업종사자비율}$$

- “제조업 종사자 비율이 1 퍼센트 증가할 때, 해당 지역의 순이동률은 0.137 만큼 증가한다.”
- “제조업 종사자 비율이 0 퍼센트인 지역의 평균 순이동률은 -4.88이다.”
- 하지만 순이동률과 관련있는 변수는 제조업 종사자 비율 이외에도 많다!



# 다중회귀모형 입문

- $k$  개의 독립변수를 모형에 투입했다면 회귀계수는 각각 대응하는 변수의 변동이 종속변수에 미치는 영향을 반영한다(Why?).
- 그러므로 다중회귀분석은 다른 변수들의 효과를 통제한 상태에서 특정 변수의 **순효과 (net effect)** 또는 **부분효과(partial effect)**를 살펴보는데 유리하다.
- 가령 제조업종사자비율 말고도 고차서비스비율 역시 순이동률에 영향을 미칠 것이다.

$$\text{순이동률} = b_0 + b_1 \cdot \text{제조업종사자비율} + b_2 \cdot \text{고차서비스비율} + e$$

- 다중회귀분석을 통해 ‘고차 서비스업 비율의 효과를 통제했을 때 (또는 고차 서비스업 비율이 똑같은 때)’ 제조업 종사자 비율이 한 단위 변화하면, 순이동률이 얼마만큼 변화하는지 살펴볼 수 있다.



연습 4. 고래는 mobility.csv를 사용하여 순이동률을 설명하는 회귀분석을 다시 한 번 수행하고자 한다. 이번에는 독립변수로 제조업종사자비율, 고차서비스비율, 지가변동율, 신규주택비율, 평균교육연수, 천명당공원면적, 만명당문화시설수를 함께 투입하기로 하였다.



## 다중회귀분석 입문

## 모함 요약

| 모형 | R                 | R 제곱 | 수정된 R 제곱 | 추정값의 표준 오차   |
|----|-------------------|------|----------|--------------|
| 1  | .703 <sup>a</sup> | .495 | .478     | 4.3970008299 |

a. 예측자: (상수), 만명당문화시설수, 지가변동율, 천명당공원면적, 고차서비스비율, 신규주택비율, 제조업종사자비율, 평균교육연수

ANOVA<sup>a</sup>

| 모형   | 제곱합      | 자유도 | 평균제곱    | F      | 유의확률               |
|------|----------|-----|---------|--------|--------------------|
| 1 회귀 | 4161.683 | 7   | 594.526 | 30.751 | <.001 <sup>b</sup> |
| 잔차   | 4253.396 | 220 | 19.334  |        |                    |
| 전체   | 8415.079 | 227 |         |        |                    |

a. 종속변수: 수이동물

b. 예측자: (상수), 만명당문화시설수, 지가변동률, 천명당공원면적, 고차서비스비율, 신규주택비율, 제조업종사자비율, 평균교육연수

계수<sup>a</sup>

| 모형 |          | 비표준화 계수 |        | 표준화 계수 | t      | 유의확률  |
|----|----------|---------|--------|--------|--------|-------|
|    |          | B       | 표준화 오류 | 베타     |        |       |
| 1  | (상수)     | -17.718 | 2.703  |        | -6.555 | <.001 |
|    | 제조업총사자비용 | .067    | .023   | .176   | 2.903  | .004  |
|    | 고차서비스비용  | -.089   | .077   | -.085  | -1.148 | .252  |
|    | 지가변동율    | .050    | .099   | .027   | .507   | .613  |
|    | 신규주택비용   | .349    | .040   | .506   | 8.627  | <.001 |
|    | 평균교육연수   | .867    | .327   | .212   | 2.649  | .009  |
|    | 천명당공원면적  | -.018   | .008   | -.111  | -2.255 | .025  |
|    | 만명당문화시설수 | .026    | .086   | .017   | .298   | .766  |

a. 종속변수: 수이동률



# 다중회귀분석 입문

다중회귀분석을 수행할 때는 변수의 사전 체크에 주의를 기울여야 한다.

- 여러 개의 독립변수를 모형에 한꺼번에 투입하다보면 하나하나를 꼼꼼하게 살펴보지 않고 그냥 대충 집어넣는 경우가 많다. 이것은 매우 위험하다!
- 개별 변수의 척도(scale)가 어떻게 구성되어 있는지, 분포(distribution)는 어떠한지, 극단치(outlier)는 없는지, 결측치(missing values)가 있는지 등을 반드시 살펴보아야 한다.
- SPSS에서도 정렬(sorting) 등을 통해 꼼꼼히 자료를 살펴보아야 하고, [그래프]-[차트 작성기]에서 '히스토그램' 등을 체크해야 한다.
- 단순회귀분석에 비해 표본 크기(sample size)가 얼마나 달라지는지도 확인해야 한다 (Why?).



# 다중회귀분석 입문

다중회귀분석에서는 보통 변수들의 역할을 구분한다.

- 관심변수(variables of interest)와 통제변수(control variables)를 구분하는 것이 대표적이다.
- 사회과학 연구에서 응용통계의 쓰임새는 결국 근거(증거)를 마련하는 것일 뿐, 우리는 나름의 핵심 주장을 가지고 있기 마련이다.
- 그 핵심 주장을 검증하기 위해 꼭 필요한 변수들이 관심변수 역할을 수행하고, 나머지는 단지 통제변수에 지나지 않는다.
- 연구 가설에 따라 “제조업 종사자 비율이 인구 순이동률에 미치는 영향”에 관심이 있다면 제조업 종사자 비율이 관심변수가 되고, 나머지 (잠재적으로 인구 순이동률에 영향을 미칠지도 모르는) 다른 모든 독립변수들은 통제변수 정도로 취급된다.
- 하지만 이것은 어디까지나 주관적으로 부여하는 의미일 뿐이고, 회귀모형 안에서 변수들의 지위는 평등하다(Why?).



# 다중회귀분석 입문

- 단순회귀분석 결과와 비교하여, 다중회귀분석에서 얻은 제조업종사자비율의 회귀계수가 어떻게 달라졌는지 꼭 비교해보자.
- 단순회귀분석에서  $b_1 = 0.1366$  였고, 다중회귀분석에서  $b_1 = 0.067$ 로 크게 감소하였다.
- 이 차이가 무엇을 의미하는지 직관적으로 탐구해보자. 다중회귀분석에서  $b_1$ 은 다른 통제변수들로 설명되고 남은 순이동률을 제조업종사자비율이 얼마나 설명하는지를 보여준다(Why?).
- 다중회귀분석 속에 투입한 독립변수의 구성에 따라 당연히  $b_1$ 이 달라진다(Why?).



## 표준화 회귀계수

# 표준화 회귀계수

여러 독립변수 중 어떤 변수가 가장 강력한 영향요인인지 궁금할 수 있다.

- 회귀계수 절대값의 크기로 변수 간 영향력의 차이를 비교할 수 없다(Why?).
- 이를 비교하기 위한 한가지 방법은 **표준화 회귀계수(standardized regression coefficient)**를 사용하는 것이다.
- 표준화에도 몇 가지 방법이 있는데 대체로 다음을 사용한다.

$$\beta_k^* = \frac{s_{X_k}}{s_Y} b_k$$

- 여러 변수들의 표준화 회귀계수를 비교하여 어떤 변수가 얼마나 중요한지 알 수 있다.



연습 5. 고래가 앞서 수행한 다중회귀분석의 결과에 따르면, 인구 순이동률의 가장 강력한 독립변수는 무엇인가?



# 표준화 회귀계수

- 순서대로 신규주택비율, 평균교육연수, 제조업종사자비율, 천명당공원면적이 중요함을 알 수 있다.
- 이때 표준화 회귀계수를 직접 해석하는 방법은 아래와 같다(Why?).
- “신규주택비율이 1 표준편차 만큼 증가할 때, 순이동률은 0.349 표준편차만큼 증가한다.”
- 경험법칙(empirical rule)에 따르면, (독립변수와 종속변수가 모두 정규분포한다는 가정 아래) 1 표준편차 증가가 상당히 큰 변화임을 시사한다. 평균에서 1, 2, 3 표준편차는 각각 전체의 68%, 95%, 99.7%를 포함하기 때문이다.
- 특히 합성변수(composite variable)를 사용할 때, 표준화 회귀계수를 통한 해석이 중요해진다(Why?).



## 모형의 적합도



# 모형의 적합도

개발한 회귀모형이 현실 자료에 얼마나 적합한지 살펴보아야 한다.

- 우리가 모형을 세워 그것을 현실 자료에 맞추어(fit) 본 이상, 이것이 얼마나 잘 맞는가를 말할 수 있어야 한다. 이것이 모형의 **적합도(goodness-of-fit)**이다.
- 우리는 여러가지 적합도 지표 가운데 **결정계수(coefficient of determination)**와 **일원분산분석(one-way ANOVA)**만 살펴보기로 한다.



# 모형의 적합도

첫번째로 결정계수를 간단히 살펴보자.

- 주어진 자료에 **전체 변량(total variation)**이 있다면, 이것은 (모형에 의해) **설명된 변량(explained variation)**과 (그렇지 못하고) **남은 변량(residual variation)**의 합이라고 분해될 수 있다.

$$\sigma_{total}^2 = \sigma_{explained}^2 + \sigma_{residual}^2$$

- 그렇다면 설명된 변량  $\sigma_{explained}^2$  와 전체 변량  $\sigma_{total}^2$  의 비율은 모형의 높은 설명력을 의미한다고 볼 수 있다.

$$R^2 = \frac{\sigma_{explained}^2}{\sigma_{total}^2} = 1 - \frac{\sigma_{residual}^2}{\sigma_{total}^2}$$

- 그러므로 결정계수  $R^2$  는 설명된 변량과 전체 변량의 비율이므로 0과 1 사이에 놓인다. 1에 가까울수록 모형은 높은 적합도를 보인다고 할 수 있다.
- 만약  $R^2$  가 0.45라면 “이 회귀모형은 주어진 자료의 전체 변량의 45% 를 설명한다”고 해석할 수 있다.

# 모형의 적합도

두번째로 일원분산분석을 간단히 살펴보자.

- 아래와 같이 선형회귀모형을 설정하였을 때 최악의 추정 결과는 무엇일까?

$$Y = \beta_0 + \beta_1 X + \cdots + \beta_{k-1} X_{k-1} + \beta_k X_k + \epsilon$$

- 그것은 모든 회귀계수가 0이 되는 상황이다(Why?)!

$$\beta_1 = \beta_2 = \cdots = \beta_{k-1} = \beta_k$$

- 제대로 된 모형이라면 최소한 이런 경우는 부정할 수 있어야 한다. 이 귀무가설조차 부정할 수 없다면, “이 모형은 완전히 쓸모없다”는 말이나 마찬가지다.



# 모형의 적합도

- 그러므로 다음과 같은 가설구조를 검증해 볼 수 있다.

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_{k-1} = 0 = \beta_k = 0$$

$$H_a : (\beta_1 \neq 0) \text{ or } (\beta_2 \neq 0) \text{ or } \cdots \text{ or } (\beta_{k-1} \neq 0) \text{ or } (\beta_k \neq 0)$$

- 이 가설구조를 테스트할 수 있는 방법은 일원분산분석(one-way ANOVA)이다.
- 다중회귀분석의 맥락에서  $F$  값은 다음과 같다. 단  $k$ 는 독립변수의 수를 뜻한다.

$$F_{(k, n-k-1)} = \frac{\sigma_{explained}^2}{\sigma_{residual}^2} = \frac{MS_{explained}}{MS_{residual}} = \frac{SS_{explained}/k}{SS_{residual}/(n-k-1)}$$

- $F$  값이 충분히 크면 유의확률( $p$ -value)이 작아지므로 위 귀무가설을 기각할 수 있다.



# 모형의 적합도

연습 6. college.sav를 사용하여 졸업생 평균수입(earnings)을 종속변수로, 학자금 상환비율(debt)과 등록금(cost)을 독립변수로 한 다중회귀분석을 수행한 뒤, 그 모형적합도를 해석하시오.



# 모형의 적합도

- “학자금 상환비율과 등록금 두 독립변수를 사용한 선형모형은 자료의 전체 변량 중 36.2%를 설명한다.”
- 0.362라는 결정계수는 너무 낮을까? 그렇지만도 않다. 겨우 두 개의 변수만으로 이 정도 설명했다는 것은 나름 훌륭하다(분과에 따라 해석이 상이하다).
- 결정계수는 보다 많은 독립변수를 집어넣을 때 지속적으로 팽창하는 성향이 있다. 그런데 이것은 **오컴의 면도날 원칙(Occam's Razor)**에 반하는 것이므로, 독립변수를 추가적으로 집어넣을 때마다 적절한 패널티를 가할 필요가 있다.
- **조정된 결정계수(adjusted  $R^2$ )**가 바로 이렇게 패널티가 가해진 결정계수이다 (여기서는 별 차이가 없었다).



# 모형의 적합도

- ANOVA 표의 유의확률이 0.001보다 작다는 사실은 99.9% 신뢰수준에서 다음의 귀무가설을 기각할 수 있다는 의미이다(Why?).

$$H_0 : \beta_1 = \beta_2 = 0$$

- 우리는 “모든 회귀계수가 0이다”라는 귀무가설을 기각하고 “최소한 하나의 회귀계수는 0이 아니다”라는 대립가설을 채택할 수 있었다. 다행이다~

ANOVA<sup>a</sup>

| 모형 |    | 제곱합          | 자유도 | 평균제곱         | F      | 유의확률               |
|----|----|--------------|-----|--------------|--------|--------------------|
| 1  | 회귀 | 2244294783.2 | 2   | 1122147391.6 | 32.065 | <.001 <sup>b</sup> |
|    | 잔차 | 3954566940.9 | 113 | 34996167.619 |        |                    |
|    | 전체 | 6198861724.1 | 115 |              |        |                    |

a. 종속변수: Earnings

b. 예측자: (상수), Debt, Cost



## 회귀분석의 결과표



# 회귀분석의 결과표

회귀분석의 결과표를 엑셀로 복사해 붙여넣고 가지런하게 꾸며야 한다.

- 회귀분석 결과표에는 SPSS에서 사용하던 변수명을 그대로 남겨두지 말고 (독자가 알아볼 수 있도록) 똑바로 고쳐써야 한다.
- 결과표 안에 회귀계수 뿐 아니라, 표준오차(standard error),  $t$  값, 또는 신뢰구간(confidence interval) 셋 중 하나는 함께 보고해야 한다(Why?).
- 통계적으로 유의하지 않았다고 포함했던 변수를 멋대로 표에서 빼서는 안된다(물론 상수도 마찬가지이다).
- 표가 너무 길어지면 (연구에서 핵심이 아닌) 변수들은 생략하는 관행도 있다. 그러나 이 경우에도 어떤 변수를 생략했는지 논문에서 반드시 보고해야 한다.



# 회귀분석의 결과표

유의확률에 관한 정보를 요약하기 위해 \*을 붙인다.

- 유의확률이 0.001보다 작으면 회귀계수 옆에 별 3개(\*\*\*), 0.01보다 작으면 별 2개(\*\*), 0.05보다 작으면 별 1개(\*), 0.1보다 작으면 대거(dagger) 하나(†)를 붙일 수 있다.
- 물론 이런 표식은 통계적으로 유의하게 귀무가설을 기각할 수 있음을 의미한다.
- 유의확률에 따른 별 붙이기는 관습의 문제이고 연구자마다 다르다(어떤 이들은 아예 붙이지 않는다).



## 회귀분석의 결과표

〈표 4〉 고3 학업성취도에 대한 회귀분석의 결과 1

|                               | 모형 1     |      | 모형 2     |      | 모형 3    |      |
|-------------------------------|----------|------|----------|------|---------|------|
|                               | 계수       | 표준오차 | 계수       | 표준오차 | 계수      | 표준오차 |
| 비밀번호 <sup>1</sup>             | .062**   | .179 | .017     | .155 | .019    | .154 |
| 중3 학업성취도                      |          |      | .509***  | .008 |         |      |
| 남성 <sup>2</sup>               |          |      |          |      | -.009   | .107 |
| 자아존중감                         |          |      |          |      | .165*** | .014 |
| 학습시간                          |          |      |          |      | .091*** | .008 |
| 학습태도                          |          |      |          |      | .355*** | .013 |
| 교사-학생 관계                      |          |      |          |      | .046*   | .019 |
| 가구소득                          |          |      |          |      | .056**  | .114 |
| 부모 관리/전문직 <sup>3</sup>        |          |      |          |      | .034    | .116 |
| 부모 태조 이상 <sup>4</sup>         |          |      |          |      | .055**  | .123 |
| 부모 감독                         |          |      |          |      | -.005   | .035 |
| 부모 애정                         |          |      |          |      | .009    | .029 |
| 4년제 대학교 졸업 부모 세대 <sup>5</sup> |          |      |          |      | .082**  | .194 |
| 대학원 졸업 부모 세대 <sup>6</sup>     |          |      |          |      | .099*** | .253 |
| 아직 정해지지 않은 부모 세대 <sup>5</sup> |          |      |          |      | .028    | .243 |
| 상수                            | 8.952*** | .065 | 6.498*** | .126 | -.819   | .985 |
| 사례수                           | 1,361    |      | 1,361    |      | 1,361   |      |
| 결정계수                          | .004     |      | .261     |      | .285    |      |

<sup>\*\*\*</sup> $p < .01$ , <sup>\*\*</sup> $p < .05$ , <sup>\*</sup> $p < .1$ .

계수는 표준화 회귀계수, 단, 상수의 계수는 비표준화 회귀계수.

기준집단: 1 = 일반고; 2 = 여성; 3 = 부모 비전문/관리직; 4 = 부모 고졸 이하; 5 = 2-3년제 전문대학 졸업 이하 부모 기대.

# 회귀분석의 결과표

연습 7. MCAS.SAV에서 (메사추세츠 주의 224개 학군별로 수집된) 학생 대 교사 비율(str), 교사의 평균 연봉(tsal), 가계소득 중앙값(inc), 한부모가계 비율(sgl)이 학업성취도 평균점수(score)와 어떤 연관성을 맺고 있는지 회귀분석을 수행하고 회귀계수 및 유의성 검정 결과를 해석하시오.



# 회귀분석의 결과표

- 세부적인 것은 (각자의 분야에서) 출판된 논문을 최대한 훑내내가면서 배운다.
- “교사의 평균 연봉(tsal), 가계소득 중앙값(inc), 한부모가계 비율(sgl)의 효과를 통제하였을 때, 학생 대 교사 비율(str)이 10% 증가할 때마다 학업성취도 평균점수는 4.96점 씩 감소한다.”

|    | A                                                                                            | B         | C       | D | E                         | F         | G       | H     | I      | J      | K     |
|----|----------------------------------------------------------------------------------------------|-----------|---------|---|---------------------------|-----------|---------|-------|--------|--------|-------|
| 1  |                                                                                              |           |         |   |                           |           |         |       |        |        |       |
| 2  |                                                                                              | 회귀계수      | 표준오차    |   | 계수 <sup>a</sup>           |           |         |       |        |        |       |
| 3  | 학생 대 교사 비율(%)                                                                                | -0.496*** | (0.131) |   | 모형                        |           | 비표준화 계수 |       | 표준화 계수 | t      | 유의확률  |
| 4  | 교사의 평균 연봉(1,000달러)                                                                           | -0.023    | (0.075) |   |                           |           | 회귀계수    | 표준오차  | 베타     |        |       |
| 5  | 가계소득 중앙값(1,000달러)                                                                            | 0.293***  | (0.034) |   | 1                         | (상수)      | 231.894 | 3.370 |        | 68.819 | 0.000 |
| 6  | 한부모가계 비율(%)                                                                                  | -0.878*** | (0.174) |   |                           | 학생 대 교사   | -0.496  | 0.131 | -0.168 | -3.794 | 0.000 |
| 7  | 상수                                                                                           | 231.9***  | (3.370) |   |                           | 교사의 평균 연봉 | -0.023  | 0.075 | -0.016 | -0.314 | 0.754 |
| 8  |                                                                                              |           |         |   |                           | 가계소득 중앙   | 0.293   | 0.034 | 0.533  | 8.511  | 0.000 |
| 9  | 표본크기                                                                                         |           | 224     |   |                           | 한부모가계 비   | -0.878  | 0.174 | -0.278 | -5.055 | 0.000 |
| 10 | 결정계수                                                                                         |           | 0.617   |   | a. 종속변수: 학업성취도 평균점수(MCAS) |           |         |       |        |        |       |
| 11 | 수정된 결정계수                                                                                     |           | 0.61    |   |                           |           |         |       |        |        |       |
| 12 | 참고: 종속변수는 학업성취도 평균점수(MCAS)임. 괄호 안은 표준오차.<br>* $p < 0.05$ , ** $p < 0.01$ , *** $p < 0.001$ . |           |         |   |                           |           |         |       |        |        |       |

