

회귀분석 응용

조절변수와 상호작용 효과

김현우, PhD¹

¹충북대학교 사회학과 조교수

July 8, 2025



진행 순서

- 1 가변수와 범주형 변수
- 2 조절변수와 상호작용 효과

가변수와 범주형 변수

가변수와 범주형 변수

회귀분석에서도 질적 차이를 드러낼 수 있다.

- 지금까지 회귀분석에서는 **등간(interval)** 또는 **비율(ratio)** 척도로 이루어진 **양적변수(quantitative variable)**만 투입하였고, “ X 가 한 단위 증가할 때, Y 는 β 만큼 증가한다”와 같이 해석하였다.
- 그러나 **명목(nominal)** 또는 **서열(ordinal)** 척도와 같은 **질적변수(qualitative variable)**를 분석할 수는 없는 것일까?
- 두 가지로 문제를 나누어 생각해보아야 한다.
 - (1) 종속변수가 질적변수라면 어떨까? 보통최소제곱(OLS)으로는 좋지 않고 **범주형 자료분석(categorical data analysis)**을 공부해야 한다.
 - (2) 독립변수가 질적변수라면 어떨까? 이때는 OLS를 사용할 수 있다. 다만 회귀식에 아무 생각없이 투입해서는 안된다!



가변수와 범주형 변수

분석에 앞서 질적 변수는 가변수로 바꾸어 사용해야 한다.

- 인종(1=백인; 2=흑인; ...), 종교(0=없음; 1=기독교; 2=불교; ...) 또는 리커트 척도(Likert scale)로 측정된 만족도(1=매우 불만족; 2=다소 불만족; 3=다소 만족; 4=매우 만족) 등은 모두 질적 변수로 볼 수 있다.
- 원칙상 이런 변수들은 그대로 회귀분석에서 독립변수로 사용할 수 없다. 해석이 이상해지기 때문이다(Why?).
- 경우에 따라 리커트 척도는 대체로 등간(approximately interval)이라고 보아 그대로 사용하기도 한다(여기에는 논란이 있다).
- 질적변수를 일단 가변수(dummy variable)로 바꾸면, 회귀분석에서 훨씬 자연스럽게 해석할 수 있다.



가변수와 범주형 변수

- Y 는 종교성(religiosity) 점수(0=매우 종교적이지 않음; ...; 100=매우 종교적임)인 단순회귀식을 다음과 같이 상정하자.

$$Y = \beta_0 + \beta_1 X$$

- X 가 양적변수인 경우 해석은 다음과 같다:
 - (1) “ X 가 한 단위 증가할 때 Y 가 β_1 만큼 변화한다.”
 - (2) “ X 가 0일 때, Y 는 β_0 와 같다.”
- X 가 가변수(e.g., 남자=0; 여자=1)라면 해석은 이렇게 변화한다.

$$\hat{Y}_{\text{남}} = \hat{\beta}_0 \quad (\text{if } X = 0)$$

$$\hat{Y}_{\text{여}} = \hat{\beta}_0 + \hat{\beta}_1 \quad (\text{if } X = 1)$$

- 남녀 간 $\hat{Y}$ 의 종교성 격차는 $\hat{Y}_{\text{여}} - \hat{Y}_{\text{남}} = \hat{\beta}_1$ 이다. 그런데 $\hat{\beta}_1$ 는 바로 가변수의 회귀계수 자체다!



가변수와 범주형 변수

가변수의 회귀계수는 곧장 남녀 간 차이를 말해준다.

- 이때 중요한 것은 ‘회귀모형에 넣지 않은 가변수 쪽을 비교 대상으로 삼는다’는 사실이다(Why?).
- 만약 아래와 같이 회귀식이 추정되었다면, 가변수 해석은 다음과 같다.

$$\text{Religiosity} = 1.81 + 0.75 \cdot \text{Female}$$

- “여자의 종교성 점수는 남자보다 0.75점 높다.”
- “남자의 종교성 점수는 평균적으로 1.81점이다.”
- 남자를 지시하는 가변수와 여자를 지시하는 가변수를 함께 회귀식에 투입할 필요는 없다(그 정보는 중복된 것이기 때문이다).



가변수와 범주형 변수

연습 1. 미국 유학을 앞둔 고래는 도시 밖에 있는 대학에 진학하면 근처에 취업할 곳이 없을 것 같아 미리 걱정하고 있다. college.sav에서 찾을 수 있는 등록금(cost), 졸업율(grad), 학자금 상환비율(debt)의 영향력을 통제하였을 때, 도시에 캠퍼스가 있는지 여부(city)가 졸업생의 평균 수입(earnings)에 어떤 미치는가를 회귀분석으로 추정하고 해석하시오.



가변수와 범주형 변수

- city는 가변수로 1인 경우에는 도시에, 0인 경우에 비도시에 입지해 있다.
- 추정된 회귀식은 다음과 같다:

$$\text{Earnings} = 10004.97 + 0.44 \cdot \text{Cost} + 178.1 \cdot \text{Grad} + 141.48 \cdot \text{Debt} + 2526.79 \cdot \text{City}$$

- “다른 변수의 영향력을 통제했을 때, 도시 대학을 졸업한 사람은 비도시 대학을 졸업한 사람보다 평균 수입이 약 2,527 달러 높다.”
- city는 95% 신뢰수준에서 통계적으로 유의하다. 그러므로 (표본을 넘어) 모집단에 대해서 $\beta = 0$ 이라는 귀무가설은 기각할 수 있다.



가변수와 범주형 변수

- cost, grad, debt의 중앙값(median)은 각각 24957.5, 67, 90이다(SPSS에서 기술통계로 알 수 있다). 이를 아래 회귀식에 대입하면 아래와 같다.

$$\begin{aligned}\text{Earnings} &= 10004.97 + 0.44 \cdot \text{Cost} + 178.1 \cdot \text{Grad} + 141.48 \cdot \text{Debt} + 2526.79 \cdot \text{City} \\ &= 10004.97 + 0.44 \cdot 24957.5 + 178.1 \cdot 67 + 141.48 \cdot 90 + 2526.79 \cdot \text{City} \\ &= 45527.13 + 2526.79 \cdot \text{City}\end{aligned}$$

- “다른 모든 변수들이 중앙값에 고정되었을 때, 비도시 대학 졸업자(city=0)의 예상되는 평균 수입은 약 45,527 달러이다.”
- “다른 모든 변수들이 중앙값에 고정되었을 때, 도시 대학 졸업자(city=1)의 예상되는 평균 수입은 약 48,054 달러이다.”
- “다른 모든 변수들이 중앙값에 고정되었을 때, 도시 대학 졸업자(city=1)는 비도시 대학 졸업자(city=0)보다 약 2,527 달러 더 많이 번다.”



가변수와 범주형 변수

물론 범주형 변수를 가변수들로 변환할 수도 있다.

- 가령 5명의 **사회경제적 지위(socioeconomic status; SES)**를 아래와 같이 세 범주(1=low; 2=middle; 3=high)로 입력하였다고 하자.

id	ses
1	low
2	middle
3	high
4	high
5	middle

- 이 변수를 쪼개 다음과 같이 **가부호화(dummy coding)**할 수 있다:
 - “ses가 low이다”를 지시하는 가변수(low)로 그렇다(1)/아니다(0).
 - “ses가 middle이다”를 지시하는 가변수(middle)로 그렇다(1)/아니다(0).
 - “ses가 high이다”를 지시하는 가변수(high)로 그렇다(1)/아니다(0).



가변수와 범주형 변수

- 사회경제적 지위(ses) 변수 하나를 3개의 가변수로 재부호화(recoding)한 셈이다.

id	ses	low	middle	high
1	low	1	0	0
2	middle	0	1	0
3	high	0	0	1
4	high	0	0	1
5	middle	0	1	0

- 잘 보면 (어디든지) 한 줄은 결국 필요가 없다. 나머지 두 줄에서 얼마든지 추측이 가능하기 때문이다.
- 그러므로 위 범주형 변수로부터 3개의 가변수를 만들었더라도, 모두 다 독립변수로 회귀모형에 집어넣을 수는 없고, 반드시 하나를 빼고 집어넣어야만 한다!



가변수와 범주형 변수

- 하나를 빼야 하는 이유는 (1) 나머지 5개의 가변수로부터 마지막 하나의 가변수 내용을 완벽하게 추측할 수 있는데, (2) 계산상의 이유로 똑같은 독립변수를 둘 이상 집어넣어서는 안되기 때문이다.
- 이렇게 빠진 변수를 **기준집단(reference group)** 또는 **기저범주(baseline category)**라고 부른다.
- 위의 연습 1에서 도시(city) 가변수 외에 비도시 가변수를 따로 넣지 않았던 이유도 여기에 있다.
- 모든 가변수의 해석은 기준집단에 비교하여 이루어진다. 그러므로 위 연습 1에서 도시(city) 가변수를 해석할 때도 회귀식에 투입하지 않은 쪽을 기준으로 해석하였다.



가변수와 범주형 변수

연습 2. college.sav 자료를 사용하여, 등록금(cost), 졸업율(grad), 학자금 상환비율(debt), 도시에 캠퍼스가 있는지 여부(city)의 영향력을 통제하였을 때, 센서스 지역(region)과 졸업생의 평균 수입(earnings) 간 연관성을 회귀분석으로 추정하고 해석하시오.



가변수와 범주형 변수

범주형 변수를 가변수로 바꾸어 처리하자.

- SPSS에서는 [데이터]-[다른 변수로 코딩변경]를 통해 재부호화할 수 있다. 별도로 엑셀을 사용할 수도 있다.
- jamovi에서는 범주형 변수만 따로 **인자(factor)**에 집어넣어 간편하게 처리할 수 있다.
- 재부호화를 할 때, 기준집단이 무엇인지 명확하게 기억하고 그에 맞추어 해석하자.



조절변수와 상호작용 효과

조절변수와 상호작용 효과


독립변수의 효과는 때로 조건부일 수도 있다.

- “경력(career)이 쌓임에 따라 임금이 증가할 것이다” 라는 가설은 단순선형회귀모형에서 쉽게 테스트될 수 있다.
- “대졸자의 임금은 비대졸자보다 높을 것이다” 라는 가설도 가변수를 활용한 단순선형회귀모형에서 쉽게 테스트될 수 있다.
- 그런데 이런 단순한 선형관계에 만족하지 않고, 한층 더 복잡한 **분기(junction)**를 고려한다면 더욱 세련된 형태로 가설과 이론을 발전시킬 수 있다.
- 가령 “경력 축적을 통한 임금 증가폭은 대졸자보다 비대졸자가 높을 것이다”와 같은 연구 가설은 (앞서 제시한 가설보다) 훨씬 세련되고 흥미롭다!



조절변수와 상호작용 효과

- 이처럼 어떤 독립변수 X 의 종속변수 Y 에 대한 효과는 조절변수(moderating variables) M_o 에 따라 상이할 수도 있다.
- (1) 독립변수 X 와 조절변수 M_o 각각의 주효과(main effects)를 먼저 살펴보고,
(2) 두 변수가 얹혀 만들어내는 상호작용 효과(interaction effect)를 추가적으로 살펴보아야 한다.
- 조절변수와 상호작용 효과를 표현하는 경로 도식(path diagram)은 다음과 같다.



조절변수와 상호작용 효과

회귀분석 안에서 상호작용 효과는 비교적 쉽게 파악할 수 있다.

- 위 사례를 토대로 두 개의 주효과에 관한 연구 가설을 세울 수 있다.
 - (1) “대졸자(collgrad)는 비대졸자보다 더 많은 임금(ln_wage)을 받을 것이다.”
 - (2) “재직경력(tenure)이 증가하면 임금(ln_wage)은 더 커질 것이다.”
- 다음으로 상호작용 효과에 관해 다음의 연구 가설을 세울 수 있다.
 - (3) “대졸자의 재직경력 증가에 따른 임금 증가폭보다 비대졸자의 재직경력 증가에 따른 임금 증가폭이 더 클 것이다.”



조절변수와 상호작용 효과

- 조절변수는 대졸 여부(collgrad)이며 다음과 같이 회귀식을 구성한다.

$$\ln_wage = b_0 + b_1 \cdot collgrad + b_2 \cdot tenure$$

- 대졸 여부(collgrad)와 재직경력(tenure)이 포함되어 있지만, 이것들로는 개별적인 효과(=주효과)만을 볼 수 있을 뿐이다.
- 이때, 재직경력의 임금 상승효과(=회귀계수)는 다음과 같이 두 부분(주효과와 상호작용 효과)으로 분해될 수 있다!

$$b_2 = \gamma_0 + \gamma_1 \cdot collgrad$$

- 위 식도 (오차항 없는) 별도의 회귀식처럼 볼 수 있다(Why?).
- 두 식을 결합하면 아래와 같다.

$$\ln_wage = b_0 + b_1 \cdot collgrad + \gamma_0 \cdot tenure + \gamma_1 \cdot (tenure \cdot collgrad)$$

조절변수와 상호작용 효과

- 결국, 독립변수인 재직경력(tenure)와 조절변수인 대졸 여부(collgrad) 외에도 두 변수를 곱한 새로운 변수가 포함되어 있다.
- 이 변수를 특별히 상호작용항(interaction term)이라고 한다.
- 곱하기 이전의 두 변수를 주요항(main terms)이라고 한다.
- 상호작용 효과를 살펴보기 위해 상호작용항 $\text{tenure} \times \text{collgrad}$ 을 넣을 때는 두 주요항 tenure 와 collgrad 을 반드시 함께 식 안에 넣어야 한다!
- 위 회귀식의 상호작용항 회귀계수 $\hat{\gamma}_1$ 에 대해 유의성 검정($H_0 : \Gamma_1 = 0$)을 한다.
- 이것이 통계적으로 유의하다면 상호작용 효과(interaction effect)가 모집단에서도 존재한다고 말할 수 있다.



조절변수와 상호작용 효과

- 상호작용항을 포함한 회귀식은 아래와 같았다.

$$\ln_wage = b_0 + b_1 \cdot tenure + b_2 \cdot collgrad + b_3 \cdot (tenure \cdot collgrad)$$

- 상호작용항을 포함한 회귀모형의 해석은 가변수의 해석과 크게 다르지 않다.

$$\ln_wage_{\text{비대졸}} = b_0 + b_1 \cdot tenure \quad (\text{if } collgrad=0)$$

$$\begin{aligned} \ln_wage_{\text{대졸}} &= b_0 + b_1 \cdot tenure + b_2 + b_3 \cdot tenure \quad (\text{if } collgrad=1) \\ &= (b_0 + b_2) + (b_1 + b_3) \cdot tenure \end{aligned}$$

- 대졸이 아닌 경우($collgrad=0$), 상수 b_0 와 회귀계수 b_1 로만 해석한다.
- 대졸인 경우($collgrad=1$), 상수 $(b_0 + b_2)$ 와 회귀계수 $(b_1 + b_3)$ 에 따라 해석한다.
- 여기서 주목할 부분은 $collgrad$ 에 따라 $tenure$ 의 상수와 회귀계수에 조금씩 부스터가 더해졌다는 점이다!



조절변수와 상호작용 효과

연습 3. `nlswork82.sav`를 사용하여 임금(`ln_wage`)을 종속변수로, 재직경력(`tenure`)과 대졸 여부(`collgrad`)를 독립변수로 하는 회귀식을 추정하시오. 이때 추가적으로 두 변수의 상호작용 효과를 고려하였을 때 결과가 어떻게 달라지는지 해석하시오.




조절변수와 상호작용 효과

- 상호작용항을 포함하지 않은 회귀식과 포함한 회귀식을 각각 따로 추정하여 그 결과를 결과표에 나란히 정리한다.
- 상호작용항을 만들기 위해서는 SPSS에서 [변환]-[변수 계산]을 선택하여 그저 두 변수를 곱하면 된다.
- 상호작용항은 99% 신뢰수준에서 통계적으로 유의하다. 이는 상호작용 효과가 (표본 뿐 아니라) 모집단에서도 존재함을 시사한다.
- 상호작용항의 회귀계수는 약 -0.017 이므로 대졸자는 재직경력이 길어질수록 임금 상승에서 (비대졸자보다) 상대적으로 조금씩 손해를 본다.
- 그러나 이 효과가 (경력 누적에 따른 임금 상승의) 주효과를 뒤집을만큼 큰 것일까?



조절변수와 상호작용 효과

- 시각화를 위해 [그래프]-[회귀 변수 도표]를 선택하고, “수직축 변수”에 `ln_wage`를, “수평축 변수”에 `tenure`를, “색상 기준”에 `collgrad`을 집어넣는다.
- “옵션”에서 “산점도 회귀선 적합”-“선형”과 “집단”에서 “각 범주형 색상 집단에 대한 회귀선 적합”을 체크한다.



조절변수와 상호작용 효과

상호작용항의 유의성 검정 절차는 조금 주의해야 한다.

- 상호작용항이 통계적으로 유의하다면, 주요항의 유의성 여부에 대해서는 별도로 신경 쓸 필요가 없다(Why?).
- 만약 상호작용항에 이론적으로 주목할 생각이 아니라면, 상호작용항을 회귀식에 넣어서는 안된다. 일단 상호작용항이 회귀식 안에 들어가면, 이것을 무시한 채 주요항만 해석할 수 없기 때문이다(Why?).
- 그러므로 상호작용항이 통계적으로 유의하지 않다면, 주요항의 유의성만이라도 판단하기 위해 상호작용항을 제거하고 다시 모형을 추정해야 한다.



조절변수와 상호작용 효과

- 상호작용을 포함한다는 것은 모형의 **복잡성(complexity)**을 늘리는 일이다.
- 과학은 **간결함(parsimony)**을 지향하므로 (상호작용항이라는 복잡성의 증대는) 그에 상응하는 설명력의 상승을 가져올 수 있어야 한다!
- 그러므로 상호작용 효과를 살펴본다면, 상호작용항을 넣지 않은 모형과 넣은 모형을 나란히 보고하는 편이 바람직하다(Why?).

	A	B	C	D	E	F
1		모형 1 (상호작용항 미포함)			모형 2 (상호작용항 포함)	
2		회귀계수	표준오차		회귀계수	표준오차
3	최종학력(1=대졸 이상; 0=고졸 이하)	0.402***	(0.022)		0.470***	(0.033)
4	재직 연수	0.039***	(0.002)		0.043***	(0.007)
5	최종학력×재직 연수				-0.017**	(0.006)
6	상수	1.490***	(0.014)		1.477***	(0.014)
7						
8	표본크기	2065				
9	결정계수	0.233			0.236	
10	참고: 종속변수는 GNP 디플레이터로 표준화된 임금(로그변환). 괄호 안은 표준오차. * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.					
11						



조절변수와 상호작용 효과

분석에 사용하는 주요항의 척도는 조금씩 다를 수 있다.

- 위 예제에서 tenure는 양적변수였고, collgrad는 가변수였다.
- 그러므로 주요항의 척도가 어떻게 구성되어 있는가에 따라 아래 세 가지 유형이 나올 수 있다(Why?):
 - (1) 양적변수 $\times$ 가변수
 - (2) 양적변수 $\times$ 양적변수
 - (3) 가변수 $\times$ 가변수.
- 위 예제는 (1) 유형이었다. (2)와 (3)은 시간 제약상 다루지 않지만 연습해보면 어렵지 않다.

