

회귀분석 응용

매개변수와 경로분석

김현우, PhD¹

¹충북대학교 사회학과 조교수

July 8, 2025



진행 순서

- 1 비선형적 관계
- 2 매개변수와 경로분석
- 3 회귀분석의 가정
- 4 회귀분석의 주의사항

비선형적 관계

비선형적 관계

회귀분석을 활용한다면 비선형적 관계도 쉽게 추정할 수 있다.

- 앞서 회귀분석은 두 변수의 관계를 요약하는 직선(best-fitting straight line)을 찾아내는 문제라고 설명하였다.
- 다시 말해, 변수 간 선형적 관계의 강도(strength of the linear relationship)만을 살펴본 셈이다.
- 그러나 회귀분석은 매우 탄력적으로 운용할 수 있어 두 변수 사이에 비선형적 관계(nonlinear relationship)라도 아래처럼 살펴볼 수 있다.

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \epsilon$$

- desmos에서 (위 회귀식과 같은) 2차방정식을 그려보자.
- 눈치빠른 학생들은 비선형적 관계와 상호작용항이 사실 수학적으로 같은 개념임을 알 수 있을 것이다(Why?).



비선형적 관계

연습 3. 새우는 hprice2.SAV를 사용하여 하위계층 비율(lowstat)에 따라 주택 가격(lprice)이 어떻게 달라지는가를 설명하고자 한다. 이때 하위계층 비율이 주택 가격에 미치는 비선형적 관계를 고려하는 회귀분석을 수행하고 이를 해석하시오.



비선형적 관계

- X^2 을 2차항(quadratic term)이라고 부른다. 단순히 제공하여 만들면 된다.
- SPSS에서는 [변환]-[변수 계산]에서 lowstat*lowstat 또는 lowstat**2을 입력한다.
- 회귀식 안에는 2차항 뿐 아니라 X 도 빼놓지 않고 투입해야 한다.
- 해석시에는 2차항에 주목하는 유의성 검정에 주목하고, 1차항은 해석하지 않는다.

$$H_0 : \beta_2 = 0$$


$$H_a : \beta_2 \neq 0$$

- 2차항이 통계적으로 유의하지 않다면, (필요에 따라) 2차항을 제거하고 다시 회귀분석을 수행하여 1차항에 대한 유의성 검정을 수행한다.
- x 와 y 의 관계를 투박하게 설명하는 이론이 있다면 좀 더 정교하게 가다듬어보자(e.g., 나이와 종교성).



비선형적 관계

- 시각화를 위해 [그래프]-[회귀 변수 도표]를 선택하고, “수직축 변수”에 lprice를, “수평축 변수”에 lowstat을 집어넣는다.
- “옵션”에서 “산점도 회귀선 적합”-“이차”를 체크해두면 2차항을 넣는 경우의 그림이 나온다.



매개변수와 경로분석

매개변수와 경로분석


관찰된 현상의 매커니즘을 어떻게 탐구할 수 있을까?

- “ X 는 Y 에 영향을 미친다”라는 가설을 세우면 보통 너무 당연하거나 너무 과격해지기 쉽다.
- 이것을 재미있게 만드는 전략 중 하나는 그러한 연관성을 만들어내는 핵심적인 내부 매커니즘을 밝혀내는 것이다!
- “ X 는 사실 M_e 를 거쳐 Y 라는 결과를 이끌어낸다.”에서 M_e 는 X 와 Y 사이의 매개변수(mediation variable)라고 말할 수 있다.



매개변수와 경로분석


- 그림 A.의 c 는 결정요인(determinant)과 결과(outcome) 사이 총효과(total effect)의 경로를 보여준다.
- 그림 B.에서 a 와 b 는 결정요인과 결과 사이 간접효과(indirect effect)의 두 경로를 보여준다.
- 그림 B.에서 c' 는 결정요인과 결과 사이 직접효과(direct effect)의 경로를 보여준다.



매개변수와 경로분석


- 아예 매개효과가 존재하지 않을 수 있다(Model 1). **부분매개(partial mediation)**만 있거나(Model 2), **전체매개(full mediation)**가 있을 수도 있다(Model 3).

Model 1:
No mediation




Path $c = c'$
 $a \text{ \&/or } b = 0$

Model 2:
General model
(Partial mediation)



Path $c = c' + (a \cdot b)$

Model 3:
Full mediation



Path $c = (a \cdot b)$
 $c' = 0$



매개변수와 경로분석

총효과는 직접효과와 간접효과의 합이다.

- 가령 1인당 교육비 지출이 수능 수학점수에 미치는 영향을 살펴본다고 하자.
- (이론적으로 까다로운 부분을 생략하고 설명하자면) 1인당 교육비 지출과 수능 수학점수 사이에는 ‘수능 응시율’라는 매개변수가 개재해 있다.
- “1인당 교육비 지출은 수능 응시율을 높인다” 그리고 “수능 응시율이 높아지면 수학점수는 낮아진다.” 그러나 “1인당 교육비 지출 자체는 수학점수를 높인다.”
- 다시 말해, 1인당 교육비 지출은 (1) 그 자체의 직접효과와 (2) 수능 응시율을 통한 간접효과를 함께 가진다.
- 이 관계를 인과 도표로 그려보자.



매개변수와 경로분석

- 총효과 ω_1 은 1인당 교육비 지출(expendpp)만을 독립변수로 하고, 수학점수(math)를 종속변수로 하여 계산한다(Why?).

$$\text{math} = \omega_0 + \omega_1 \cdot \text{expendpp}$$

- 간접효과의 첫번째 경로 γ_1 은 1인당 교육비 지출(expendpp)을 독립변수로 하고, 수능 응시율(perctakers)을 종속변수로 하여 계산할 수 있다.

$$\text{perctakers} = \gamma_0 + \gamma_1 \cdot \text{expendpp}$$

- 간접효과의 두번째 경로 β_2 은 1인당 교육비 지출(expendpp)과 수능 응시율(perctakers)을 독립변수로 하고, 수학점수(math)를 종속변수로 하여 계산한다(Why?).

$$\text{math} = \beta_0 + \beta_1 \cdot \text{expendpp} + \beta_2 \cdot \text{perctakers}$$

- 이때 직접효과는 위의 β_1 이다(Why?).



매개변수와 경로분석

연습 4. Guber99.sav에서 SAT 수학과목의 평균성적(math)을 예측하기 위해, 1인당 교육비 지출(expendpp), SAT 응시가능 학생 비율(perctakers)을 독립변수로 하는 회귀분석을 수행하시오. 1인당 교육비 지출의 총효과, 직접효과, 간접효과를 적절히 해석하시오.



매개변수와 경로분석

- 효과의 크기는 일반적으로 표준화 회귀계수를 사용한다. 인과도표(causal diagram)에 효과의 크기를 표시할 때도 마찬가지다.
- 총효과는 약 -10.308 정도가 된다.
- 직접효과는 약 7.539 이고, 간접효과는 11.638×-1.534 이다.
- 물론 직접효과와 간접효과의 합은 총효과와 일치한다(이것으로 검증한다).



매개변수와 경로분석

조절효과와 매개효과는 다른 개념이며 구별되어야 한다.

- (1) 조절효과(moderation effect)는 상호작용 효과(interaction effect)를 통해,
- (2) 매개효과(mediation effect)는 위계적 회귀분석(hierarchical linear regression analysis) 그리고/또는 경로분석(path analysis)에서 살펴본다.
- 이 특강에서는 시간 부족으로 매개효과를 자세히 다루지 못하지만, (1) Baron-Kenny 매개분석에 관한 여러 교과서와 논문을 참고하고, (2) 더 나아가 구조방정식모형(structural equation modeling)을 공부하는 것을 추천한다.



회귀분석의 가정

회귀분석의 가정

보통최소제곱 알고리즘은 사실 몇 가지 가정에 입각하고 있다.

- 이 가정들은 (1) 보통최소제곱의 해(solution)가 존재하고, (2) 보통최소제곱(OLS) 추정량이 어째서 **왜곡이 없으며(unbiased)**, (3) 다른 추정량보다 작은 표준오차만을 가지는지, 즉 **효율적(efficient)**인지 증명하는데 조용히 쓰인다.
- 교과서에 따라 가정의 목록이 조금씩 다르게 설명된다. 일단 다음의 두 형태로 구분해보자.
 - (1) **고전적 가정(classical assumption)**
 - (2) 오차항 ϵ 에 대한 가정



회귀분석의 가정

- 먼저 회귀모형에 대한 고전적 가정은 다음과 같다.
 - (1) 선형성(linearity): Y 와 X 의 관계는 선형적으로(linearly) 표현된다.
 - (2) 완전공선성 없음(no perfect collinearity): 똑같은 독립변수 두 개 이상 넣지 않는다.
 - (3) 비확률적 독립변수(non-stochastic X s): 독립변수는 외생적이다.
- 어떤 교과서는 (4) 극단치 없음(no outliers)을 포함하기도 한다. (분명히 필요하긴 하지만) 가정이라고 하기엔 좀 무리가 있다.
- 물론 위에 더하여 오차항에 대한 가정도 필요하다!



회귀분석의 가정

- 다음과 같이 오차항 ϵ 에 대한 가정을 나열할 수 있다.

(1) 외생성(exogeneity)/조건부 영평균(zero conditional mean)

$$E(\epsilon_i | X_i) = 0$$

(2a) 등분산성(homoscedasticity)

$$Var(\epsilon_i | X) = Cov(\epsilon_i, \epsilon_i) = \sigma^2$$

(2b) 자기상관 없음(no autocorrelation)

$$Cov(\epsilon_i, \epsilon_j) = 0$$

- 그리고 위 가정들보다 좀 더 강한 가정 하나를 “편의상” 추가한다.

(3) 정규성(normality)

$$\epsilon_i \sim N(0, \sigma^2)$$



회귀분석의 가정

회귀분석의 가정은 고급통계학의 관문과도 같다.

- 회귀모형에서 가정이 깨지면 더이상 OLS가 최적이라고 보장할 수 없다.
- 그러나 가정이 깨져도 이에 대응하는 별도의 기법이 존재한다. 이 고급 기법들은 각각의 가정 위배에 대응하여 다루어진다.
- 그런 의미에서 OLS의 가정에 관해 심도있게 학습하는 것은 고급통계학으로의 관문 (gateway)으로 이어진다고 할 수 있다.
- $1 + 1 = 2$ 를 배우는 것은 금방이지만 왜 이 식이 성립하는지 **공리(axioms)**나 가정을 공부하는 것은 어렵다.
- 더 본격적으로 회귀분석을 공부한다면 가정에 대해 꼼꼼히 학습하고 그 진단과 대응책 역시 다루게 된다.



회귀분석의 주의사항

회귀분석의 주의사항

우리가 배운 회귀분석은 인과분석이 아니다.

- “상관분석은 상관관계를 살펴보고, 회귀분석은 인과관계를 살펴본다”는 식의 헛소문은 전혀 사실이 아니다.
- 회귀분석을 통해 계산된 회귀계수는 사실 수학적으로 꼼꼼히 따져보면 표준화된 상관계수에 불과하다.
- 비실험적 자료(non-experimental data) 혹은 관찰자료(observational data)를 가지고 평범하게 회귀분석하였다면 단지 상관관계만을 파악한 것이다.
- 물론 인과관계가 아니라고 연구로서 무가치해지는 것은 아니다. 다만 회귀분석의 결과를 해석할 때 (실험설계가 아닌 이상) 마치 인과관계인 것처럼 말하지 않아야 한다.



회귀분석의 주의사항

- 보다 엄격한 인과분석을 위한 **설계계획(design of experiment: DoE)**이 있으며 이것은 앞으로도 계속해서 중요한 분야가 될 것이다.
- 일정 기간에 걸쳐 반복적으로 추적 조사한 자료를 **종단분석(longitudinal analysis)**하는 기법이 있으며 이 또한 중요한 방법론이다.
- **횡단면 자료(cross-sectional data)**인 경우에도 **도구변수(instrumental variable)**나 **경향점수(propensity score)** 등을 활용하여 보다 엄격하게 인과적 관계를 추론하려는 접근방법도 있다.
- 이 모든 방법론은 향후 그 중요성을 점점 더할 것으로 전망된다.



회귀분석의 주의사항

통계적 유의성과 실질적 유의성은 다른 개념이다

- 통계적 유의성(statistical significance)을 해석할 때 가장 흔한 실수 중 하나는 유의확률(p -value)이 얼마나 작은가를 두고 연관성의 강도(strength of association)로 해석하는 것이다.
- 곰곰히 생각해보면, 유의확률은 단지 $H_0 : \beta = 0$ 라는 귀무가설을 전제하고 그려진 표집분포에서 (그렇게 극단적인) 표본 추정량이 나올 확률을 보여줄 뿐이다.

회귀분석의 주의사항

- **실질적 유의성(substantial significance)**은 통계적으로 유의한가 여부와 상관없이 실제로 얼마나 그 강도가 센가의 문제를 다룬다.
- 예컨대 한 시간 게임을 더하게 되면 독서시간이 2분 줄어든다는 발견(Cummings and Vandewater 2007)은 설령 통계적으로 유의하더라도 실질적으로는 그다지 유의하지 않다.
- 그러므로 통계적으로 유의한 결과를 얻었더라도 그 관계를 “실질적인 의미가 담겨있는 언어로 해석하고 음미하여” 실질적 유의성이 얼마나 높은지 판단할 필요가 있다.

Cummings, Hope M. and Elizabeth A. Vandewater. 2007. “Relation of Adolescent Video Game Play to Time Spent in Other Activities.” Archives of Pediatrics Adolescent Medicine 161(7): 684-689.