

회귀분석 응용

질적변수

김현우, PhD¹

¹충북대학교 사회학과 부교수

July 14, 2026



진행 순서

- 1 가변수와 범주형 변수
- 2 독립변수가 질적변수인 경우
- 3 종속변수가 질적변수인 경우



가변수와 범주형 변수



가변수와 범주형 변수

회귀분석에서도 질적 차이를 드러낼 수 있다.

- 지금까지 회귀분석에서는 **등간(interval)** 또는 **비율(ratio)** 척도로 이루어진 **양적변수(quantitative variable)**만 투입하였고, “ X 가 한 단위 증가할 때, Y 는 β 만큼 증가한다”와 같이 해석하였다.
- 그러나 **명목(nominal)** 또는 **서열(ordinal)** 척도와 같은 **질적변수(qualitative variable)**를 분석할 수는 없는 것일까?
- 두 가지로 문제를 나누어 생각해보아야 한다.
 - (1) 독립변수가 질적변수인 경우
 - (2) 종속변수가 질적변수인 경우



가변수와 범주형 변수

분석에 앞서 질적 변수는 가변수로 바꾸어 사용해야 한다.

- 인종(1=백인; 2=흑인; ...), 종교(0=없음; 1=기독교; 2=불교; ...) 또는 **리커트 척도 (Likert scale)**로 측정된 만족도(1=매우 불만족; 2=다소 불만족; 3=다소 만족; 4=매우 만족) 등은 모두 질적 변수로 볼 수 있다.
- 원칙상 이런 변수들은 그대로 회귀분석에서 독립변수로 사용할 수 없다. 해석이 이상해지기 때문이다(Why?).
- 경우에 따라 리커트 척도는 **대체로 등간(approximately interval)**이라고 보아 그대로 사용하기도 한다(여기에는 논란이 있다).
- 질적변수를 일단 **가변수(dummy variable)**로 바꾸면, 회귀분석에서도 자연스럽게 해석할 수 있다.



독립변수가 질적변수인 경우



독립변수가 질적변수인 경우

- Y 는 종교성(religiosity) 점수(0=매우 종교적이지 않음; ...; 100=매우 종교적임)인 단순회귀식을 다음과 같이 상정하자.

$$Y = \beta_0 + \beta_1 X$$

- X 가 양적변수인 경우 해석은 다음과 같다:
 - (1) “ X 가 한 단위 증가할 때 Y 가 β_1 만큼 변화한다.”
 - (2) “ X 가 0일 때, Y 는 β_0 와 같다.”
- 만일 X 가 가변수(e.g., 남자=0; 여자=1)라면 해석은 이렇게 변화한다.

$$\hat{Y}_{\text{남}} = \hat{\beta}_0 \quad (\text{if } X = 0)$$

$$\hat{Y}_{\text{여}} = \hat{\beta}_0 + \hat{\beta}_1 \quad (\text{if } X = 1)$$

- 남녀 간 $\hat{Y}$ 의 종교성 격차는 $\hat{Y}_{\text{여}} - \hat{Y}_{\text{남}} = \hat{\beta}_1$ 이다. 그런데 $\hat{\beta}_1$ 는 바로 가변수의 회귀계수 자체다!

독립변수가 질적변수인 경우

가변수의 회귀계수는 곧장 남녀 간 차이를 말해준다.

- 이때 중요한 것은 ‘회귀모형에 넣지 않은 가변수 쪽을 비교 대상으로 삼는다’는 사실이다(Why?).
- 만약 아래와 같이 회귀식이 추정되었다면, 가변수 해석은 다음과 같다.

$$\text{Religiosity} = 1.81 + 0.75 \cdot \text{Female}$$

- “여자의 종교성 점수는 남자보다 0.75점 높다.”
- “남자의 종교성 점수는 평균적으로 1.81점이다.”
- 남자를 지시하는 가변수와 여자를 지시하는 가변수를 함께 회귀식에 투입할 필요는 없다(그 정보는 중복된 것이기 때문이다).



독립변수가 질적변수인 경우

연습 1. 미국 유학을 앞둔 고래는 도시 밖에 있는 대학에 진학하면 근처에 취업할 곳이 없을 것 같아 미리 걱정하고 있다. college.sav에서 찾을 수 있는 등록금(cost), 졸업율(grad), 학자금 상환비율(debt)의 영향력을 통제하였을 때, 도시에 캠퍼스가 있는지 여부(city)가 졸업생의 평균 수입(earnings)에 어떤 미치는가를 회귀분석으로 추정하고 해석하시오.



독립변수가 질적변수인 경우

- city는 가변수로 1인 경우에는 도시에, 0인 경우에 비도시에 입지해 있다.
- 추정된 회귀식은 다음과 같다:

$$\text{Earnings} = 10004.97 + 0.44 \cdot \text{Cost} + 178.1 \cdot \text{Grad} + 141.48 \cdot \text{Debt} + 2526.79 \cdot \text{City}$$

- “다른 변수의 영향력을 통제했을 때, 도시 대학을 졸업한 사람은 비도시 대학을 졸업한 사람보다 평균 수입이 약 2,527 달러 높다.”
- city는 95% 신뢰수준에서 통계적으로 유의하다. 그러므로 (표본을 넘어) 모집단에 대해서 $\beta = 0$ 이라는 귀무가설은 기각할 수 있다.



독립변수가 질적변수인 경우

- cost, grad, debt의 중앙값(median)은 각각 24957.5, 67, 90이다(기술통계로 알 수 있다). 이를 아래 회귀식에 대입하면 아래와 같다.

$$\begin{aligned}\text{Earnings} &= 10004.97 + 0.44 \cdot \text{Cost} + 178.1 \cdot \text{Grad} + 141.48 \cdot \text{Debt} + 2526.79 \cdot \text{City} \\ &= 10004.97 + 0.44 \cdot 24957.5 + 178.1 \cdot 67 + 141.48 \cdot 90 + 2526.79 \cdot \text{City} \\ &= 45527.13 + 2526.79 \cdot \text{City}\end{aligned}$$

- “다른 모든 변수들이 중앙값에 고정되었을 때, 비도시 대학 졸업자(city=0)의 예상되는 평균 수입은 약 45,527 달러이다.”
- “다른 모든 변수들이 중앙값에 고정되었을 때, 도시 대학 졸업자(city=1)의 예상되는 평균 수입은 약 48,054 달러이다.”
- “다른 모든 변수들이 중앙값에 고정되었을 때, 도시 대학 졸업자(city=1)는 비도시 대학 졸업자(city=0)보다 약 2,527 달러 더 많이 번다.”



독립변수가 질적변수인 경우

물론 범주형 변수를 가변수들로 변환할 수도 있다.

- 가령 5명의 **사회경제적 지위(socioeconomic status; SES)**를 아래와 같이 세 범주 (1=low; 2=middle; 3=high)로 입력하였다고 하자.

id	ses
1	low
2	middle
3	high
4	high
5	middle

- 이 변수를 쪼개 다음과 같이 **가부호화(dummy coding)**할 수 있다:
 - “ses가 low이다”를 지시하는 가변수(low)로 그렇다(1)/아니다(0).
 - “ses가 middle이다”를 지시하는 가변수(middle)로 그렇다(1)/아니다(0).
 - “ses가 high이다”를 지시하는 가변수(high)로 그렇다(1)/아니다(0).



독립변수가 질적변수인 경우

- 사회경제적 지위(ses) 변수 하나를 3개의 가변수로 **재부호화(recoding)**한 셈이다.

id	ses	low	middle	high
1	low	1	0	0
2	middle	0	1	0
3	high	0	0	1
4	high	0	0	1
5	middle	0	1	0

- 잘 보면 (어디든지) 한 줄은 결국 필요가 없다. 나머지 두 줄에서 얼마든지 추측이 가능하기 때문이다.
- 그러므로 위 범주형 변수로부터 3개의 가변수를 만들었더라도, 모두 다 독립변수로 회귀모형에 집어넣을 수는 없고, 반드시 하나를 빼고 집어넣어야만 한다!



독립변수가 질적변수인 경우

- 하나를 빼야 하는 이유는 (1) 나머지 5개의 가변수로부터 마지막 하나의 가변수 내용을 완벽하게 추측할 수 있는데, (2) 계산상의 이유로 똑같은 독립변수를 둘 이상 집어넣어서는 안되기 때문이다.
- 이렇게 빠진 변수를 **기준집단(reference group)** 또는 **기저범주(baseline category)**라고 부른다.
- 위의 연습 1에서 도시(city) 가변수 외에 비도시 가변수를 따로 넣지 않았던 이유도 여기에 있다.
- 모든 가변수의 해석은 기준집단에 비교하여 이루어진다. 그러므로 위 연습 1에서 도시(city) 가변수를 해석할 때도 회귀식에 투입하지 않은 쪽을 기준으로 해석하였다.



독립변수가 질적변수인 경우

연습 2. college.sav 자료를 사용하여, 등록금(cost), 졸업율(grad), 학자금 상환비율(debt), 도시에 캠퍼스가 있는지 여부(city)의 영향력을 통제하였을 때, 센서스 지역(region)과 졸업생의 평균 수입(earnings) 간 연관성을 회귀분석으로 추정하고 해석하시오.



독립변수가 질적변수인 경우

범주형 변수를 가변수로 바꾸어 처리하자.

- Jamovi에서 Variables-Transform로 작업할 수도 있다. 보다 편리하게 OneHotEncoding 같은 외부 모듈을 사용할 수도 있다. 아예 처음부터 엑셀을 사용하여 가변수로 변환해 둘 수 있다.
- 회귀분석 단계에서 범주형 변수만 따로 (Covariates이 아니라) Factors에 집어넣어 간편하게 처리할 수 있다.
- 재부호화를 할 때, 기준집단이 무엇인지 명확하게 기억하고 그에 맞추어 해석하자.



종속변수가 질적변수인 경우



종속변수가 질적변수인 경우

종속변수가 질적변수라면 회귀분석을 사용할 수 있을까?

- 연구나 실무에서 다음과 같은 종속변수를 갖는 경우가 제법 흔하다.
 - (1) 지난 대선 투표 참여 여부 (0=불참, 1=참여)
 - (2) 주관적 행복 수준 (1=매우 불행, 2=다소 불행, 3=불행하지도 행복하지도 않음, 4=다소 행복, 5=매우 행복)
 - (3) 여가활동의 종류 (0=무관심형, 1=관람형, 2=참여형, 3=혼합형)
- 잘 생각해보면 종속변수가 질적변수인 경우는 다음 세 가지 상황에 대응한다.
 - (1) 종속변수가 가변수인 경우
 - (2) 종속변수가 서열척도인 경우
 - (3) 종속변수가 범주형 변수인 경우
- 이를 위해 (이 워크샵의 범위를 넘어) **범주형 자료 분석(categorical data analysis)**을 공부해야 한다.



종속변수가 질적변수인 경우

종속변수가 가변수인 경우 그냥 OLS 회귀분석을 사용해 볼 수 있다.

- 만일 종속변수 Y 가 가변수(0=투표 불참, 1=투표 참여)이고, 독립변수 X 가 교육연수라면 다음의 회귀식은 어떤 의미를 가질까?

$$E(Y|X) = \hat{\beta}_0 + \hat{\beta}_1 X$$

- “교육연수 X 가 한 해 증가할 때 투표 참여 여부 Y 는 $\hat{\beta}_1$ 만큼 증가(또는 감소)한다.”
- “교육연수 X 가 0일 때, 투표 참여 여부 Y 는 $\hat{\beta}_0$ 이다.”
- 이상하게 들릴까? 사실 잘 따져보면 그렇지만도 않다!



종속변수가 질적변수인 경우

종속변수가 0 또는 1이라면 그것이 백분율처럼 해석될 수 있기 때문이다!

- 종속변수가 가변수라서 0 또는 1이 아니라, 이게 진짜 양적변수라서 0과 1 사이에 있는 어떤 백분율 값이라고 상상해보자. 그리고 다시 해석해보자.
- “교육연수 X 가 한 해 증가할 때 투표 참여 확률 Y 는 $\hat{\beta}_1 \times 100$ 만큼 증가(또는 감소)한다.”
- “교육연수 X 가 0일 때, 투표 참여 확률 Y 는 $\hat{\beta}_0 \times 100$ 이다.”
- 단지 참여 여부가 아니라 참여 확률로 바뀌었을 뿐인데, 해석이 제법 자연스러워졌다.



종속변수가 질적변수인 경우

- 참여 여부와 참여 확률의 차이는 0과 1 사이에 어떤 값이 존재할 수 있는가에 달려있다.
- 물론 종속변수는 가변수라서 사실 0과 1 사이에 어떤 값을 가질 수 없다.
- 하지만 마치 그럴수 있는 것처럼 상정하는 접근방법을 **선형확률모형(linear probability model)**이라고 부른다.

$$E(Y|X) = P(Y = 1|X) = \hat{\beta}_0 + \hat{\beta}_1 X$$

- 해석할 때는 아까처럼 참여 여부 대신 참여 확률로 간다!



종속변수가 질적변수인 경우

연습 3. lowbwt.sav에서 산모의 마지막 월경시 체중(lwt)을 독립변수로, 영아의 출생시 체중(bwt)을 종속변수로 한 회귀식을 추정하고 그 결과를 해석하시오. 다음으로 같은 독립변수를 사용하되, 저출생체중아 여부(low)를 종속변수로 한 별도의 회귀식을 추정하고 그 결과를 해석하시오. 두 모형을 비교하시오.



종속변수가 질적변수인 경우

	모형 1 (OLS)		모형 2 (OLS)	
	bwt		low	
엄마의 마지막 생리전 체중	4.430*	(1.713)	-0.003*	(0.001)
상수	2369.2***	(228.5)	0.646***	(0.146)
F	6.686*		5.524*	
결정계수	0.0345		0.0287	
사례수	189			
노트: 괄호 안에 표준오차. * p<0.05, ** p<0.01, *** p<0.001.				




종속변수가 질적변수인 경우

- 먼저 `bwt`를 종속변수로, `lwt`를 독립변수로 삼아 OLS 회귀분석을 수행한다.
- “산모의 체중이 1 파운드 증가하면 아이의 출생시 체중이 4.43g 증가하고, 이는 95% 신뢰수준에서 통계적으로 유의하다.”
- 다음으로 `low`를 종속변수로, `lwt`를 독립변수로 삼아 OLS 회귀분석을 수행한다 (선형확률모형).
- “산모의 체중이 1 파운드 증가하면 아이의 출생시 저체중일 확률이 0.3% 감소하고, 이는 95% 신뢰수준에서 통계적으로 유의하다.”




종속변수가 질적변수인 경우

- 우리에게 가장 이상적인 상황은 첫번째(bwt)처럼 자료가 주어졌을 때이다.



종속변수가 질적변수인 경우

- 하지만 후자(low)로 자료가 주어졌을 수도 있다. 두 변수의 관계는 다음과 같다.



종속변수가 질적변수인 경우

이 상황에서 OLS는 원칙적으로 타당하지 못한 추정법이다.

- 이때는 보통최소제곱(OLS)이 아니라 (우리가 배운 적 없는) **최대우도법(maximum likelihood estimation; MLE)**을 통해 회귀계수와 상수를 추정해야 한다.
- **로지스틱 회귀분석(logistic regression analysis)**이 바로 최대우도법에 따라 회귀계수와 상수를 추정하는 대표적인 기법이다.
- 함부로 말하기는 조심스럽지만, (특수한 예외를 제외하면) 종속변수가 가변수인 상황에서 OLS 알고리즘과 MLE 알고리즘의 추정량은 결국 비슷한 방향인 경우가 많다.



종속변수가 질적변수인 경우

- (다소 불완전하지만) 선형확률모형을 명확히 해석하기 위해 단순히 회귀식만 제시하기 보다 시각화하자.
- 시각화를 하려면 먼저 아래처럼 **예측확률(predicted probability)**을 계산해야 한다.


$$P(Y = 1|X) = \hat{\beta}_0 + \hat{\beta}_1 X$$

- 선형회귀분석을 수행할 때, Save에서 Predicted values를 체크하여 $\hat{Y}$ 을 새로 만들어 저장하자.
- 이제 산모의 마지막 월경시 몸무게(1wt)와 $\hat{Y}$ 의 연관성을 보여주는 산점도를 그려보자.



종속변수가 질적변수인 경우

- 참고로 MLE로 계산된 예측확률과 OLS로 계산된 예측확률 간 상관계수는 0.99이다.



종속변수가 질적변수인 경우

연습 4. lowbwt.sav에서 저출생체중아 여부(low)를 종속변수로 하고, 산모연령(age), 임신중 흡연 여부(smoke), 고혈압(ht), 자극성 자궁(ui), 엄마의 마지막 월경시 체중(lwt), 인종(race), 미숙아 출산력(pt1) 그리고 산과 방문수(ftv)를 독립변수로 하는 회귀식을 추정하고 그 결과를 해석하시오. 인종에 따른 저출생체중아 출산확률을 시각화하시오.




종속변수가 질적변수인 경우

- 우리의 관심변수(variable of interest)인 인종(race)은 범주형 변수이므로 가변수로 바꾸어 회귀분석을 수행해야 한다.
- 그런데 가변수이므로 아까처럼 산점도와 적합선을 그릴 수는 없다(Why?).
- 대신 양적변수와 질적변수의 관계를 살펴보기에 적절한 상자-수염 그림을 그리면 된다!
- 인종(race)과 $\hat{Y}$ 사이 연관성을 살펴보자.



종속변수가 질적변수인 경우



종속변수가 질적변수인 경우

- Jamovi에서 [Analyses]-[Regression]-[2 Outcomes]를 선택하면 로지스틱 회귀분석을 수행할 수 있다(아래 표의 오른쪽 결과를 참고하자).

Predictor	OLS Estimate	SE	sig.	MLE Estimate	SE	sig.
Intercept	0.51	0.21	*	0.48	1.20	*
age	0.00	0.01		-0.03	0.04	
smoke	0.16	0.07	*	0.94	0.40	*
ht	0.37	0.14	**	1.86	0.70	**
ui	0.16	0.09		0.77	0.46	
lwt	0.00	0.00	*	-0.02	0.01	*
race:						
Black – White	0.22	0.10	*	1.27	0.53	*
Other – White	0.14	0.08		0.88	0.44	*
ptl	0.12	0.07		0.54	0.35	
ftv	0.01	0.03		0.07	0.17	

Note: MLE Estimates represent the log odds of "low = 1" vs. "low = 0". * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.

